Un pipeline de normalisation et validation d'adresses postales

Dérnière mise à jour: 03-04-2026

1- Traitement Adresse

Étape 0 — Consolidation des sources

0- Préparation de la table contenant toutes les adresses des OGR.sas

- rassemble les adresses provenant de multiples sources
  - Pages Jaunes
  - TripadVisor

Étape 1 — Traitement automatique (« Appelé 1 »)

Appelé 1-Traitement adresse.sas

- orchestre ~21 macros enchaînées qui découpent une adresse brute (champ texte unique)
  - Program sas : MacroAdr1 — Nettoyage des caractères spéciaux et accents
    - Les accents sont retirés (é→e, ç→c, ô→o, etc.)
    - Tous les symboles deviennent des espaces : -, _, /, (,), @, :, ', ", etc.
    - Mise en MAJUSCULES
    - Suppression des espaces multiples
    - AVANT : "12, Bd Victor-Hugo — 75016 PARIS Cédex"
APRÈS : "12 BD VICTOR HUGO 75016 PARIS CEDEX"
  - Program sas : MacroAdr2 — Extraction du code postal et de la ville
    - AVANT : "12 BD VICTOR HUGO 75016 PARIS"
APRÈS : adresse="12 BD VICTOR HUGO" | codpost="75016" | ville="PARIS"
  - Program sas : MacroAdr3 — Normalisation des expressions courantes
    - La plus grosse étape. Elle standardise des centaines d'abréviations et de variantes (x2)
  - Program sas : MacroAdr4/5 — Normalisation BP (boîte postale) et CP
  - Program sas : MacroAdr6 — Normalisation du type de voie (RUE, AVENUE...)
  - Program sas : MacroAdr7 — Traitement des CEDEX
  - Program sas : MacroAdr8/9 — Extraction des zones (ZAC, ZI, centre commercial...)
  - Program sas : MacroAdr12-18 — Extraction du numéro de voie, BIS/TER, type de voie
  - Program sas : MacroAdr21 — Suppression des espaces multiples

  → Résultat — l'adresse brute "12 BIS RUE VICTOR HUGO 75001 PARIS" est éclatée en → numvoie=12, compvoie=BIS, typevoie=RUE, nomvoie=VICTOR HUGO, codpost=75001, ville=PARIS

Étape 2 — Corrections manuelles connues (« Appelé 2 »)

Appelé 2- Correction séparation auto vues précedemment.sas

- applique des corrections cas par cas — des adresses mal découpées identifiées les années précédentes
  - base de connaissances des erreurs connues
    1. Corrections « en dur » cas par cas — 5 grandes familles d'erreurs corrigées
       - Ville polluée — ville="1 R VASCO DE GAMA 44955 NANTES" — On redistribue : numvoie="1", typevoie="RUE", nomvoie="VASCO DE GAMA", codpost="44955", ville="NANTES"
       - Nom de voie trop long (contient un complément collé) — nomvoie="JEAN JAURES L ORANGERIE" — On coupe : nomvoie="JEAN JAURES", compvoie="L ORANGERIE"
       - Type de voie absorbé dans le nom — nomvoie="R AMIRAL COURBET" — On extrait : typevoie="RUE", nomvoie="AMIRAL COURBET"
       - Code postal / ville mélangés — ville="35517 CESSON SEVIGNE" — On sépare : codpost="35517", ville="CESSON SEVIGNE"
       - Fautes d'orthographe — nomvoie="CHARLES DE GAULLE" — → "CHARLES DE GAULLE"
    2. Nettoyages semi-génériques
    3. Macros de vérification — appelle des macros de contrôle
macro1_7a à macro1_7f
       - Le numvoie ne contient-il pas de texte parasite (ex: 32RR) ?
       - Le nomvoie contient-il encore un type de voie non extrait ?
       - typevoie vide alors que numvoie rempli → incohérence ?
       - typevoie vide → cas à investiguer
       - nomvoie contient des mots comme « AGENCE », « SALLE COURRIER » → à nettoyer

Étape 3 — Validation manuelle

1- Traitement adresse auto et vérification des adresses - Fichiers BAN.sas

- Phase 1 - Génère une clé unique par adresse (cle = dep + compvoie + codpost + ville + numvoie + typevoie + nomvoie)
  - 75CIMMEUBLE APOLLO75001PARIS12TRUEVICTOR HUGO → c'est l'identité unique de cette adresse découpée
- Phase 2 - Compare avec la table ValidManAdrExtracOK (corrections manuelles déjà validées)
  - Un MERGE par clé sépare les adresses en deux flux
    - Adress auto valide : ADRAutoOK
      - Clé trouvée dans l'historique
      - Adresse déjà validée une année précédente → on réutilise la correction
    - Adress à valide manuellement : AdrManuel
      - Clé absente de l'historique
      - Adresse nouvelle → à envoyer en validation manuelle

    C'est le mécanisme d'apprentissage cumulatif : chaque année, le volume à valider manuellement diminue car les corrections s'accumulent.
- Phase 3 - Sépare en ADRAutoOK (déjà validées) et AdrManuel (à valider manuellement)
  - Export pour validation humaine — La table AdrManuel est enrichie avec le nom de l'agence (pour aider le validateur) puis exportée en Excel — Le fichier contient les colonnes de l'adresse découpée automatiquement + 6 colonnes vides pour les corrections :
    - Colonnes auto (lecture seule) — numvoie, typevoie, nomvoie, compvoie, codpost, ville
    - Colonnes manuelles (à remplir) — numvoie2, typevoie2, nomvoie2, compvoie2, codpost2, ville2
- Phase 4 - PAUSE : Validation humaine
  - Surligner en jaune les lignes où codpost ou ville sont vides
  - Pour corriger un champ — remplir la colonne *2 correspondante (ex: nomvoie2)
  - Pour vider un champ → écrire "VIDE" dans la colonne *2
  - Pour supprimer une ligne (pas une adresse) → mettre "VIDE" dans nomvoie2
  - Points de vigilance
    1 - Vérifier que numvoie ne contient pas de texte parasite
    2 - Le codpost doit faire exactement 5 chiffres
    3 - La ville doit être remplie pour tout le monde
    4 - Si nomvoie contient encore un complément collé → le séparer dans compvoie2
    5 - Attention aux numéros de voie très grands (souvent suspects)
  - Le fichier validé est sauvegardé sous — ValidManAdrExtractionOK.xlsx.
- Phase 5 - Réimport et fusion
  - Import du fichier Excel validé
  - Re-merge avec toutes les adresses pour appliquer les corrections
  - Application des corrections : — si *2 contient une valeur → elle remplace le champ original ; si *2 = "VIDE" → le champ est vidé ; si nomvoie2 = "VIDE" → la ligne est supprimée
  - Nettoyage final : suppression des adresses sans nom de voie, des adresses en Andorre, recalcul du département

2- Géocodage commune

Phase 1 — Normalisation de la ville (villenorm)

Transformer le champ ville (saisi/extrait, avec erreurs) en un champ villenorm correspondant à un nom de commune officiel.

- Étape 1.1 — Préparation
  - Création du champ NOM (nom de l'établissement) pour aider aux rapprochements
  - Nettoyage du champ ville via %macroAdr1 (suppression accents, symboles)
  - Suppression de cas étrangers (Luxembourg, Suisse, Allemagne, Andorre)
  - Suppression des adresses vides ou avec dep="98" (Monaco, étranger)
- Étape 1.2 — Rapprochement automatique en 3 passes
  - codpost + villevalid (ville avec ST/STE) — Table de référence : geo.listevillenorm — → ficvilleok (OK) ou passe 2
  - typevoie + nomvoie + compvoie + codpost + ville — Table de référence geo.corvilleparadr — → ficvilleok2 (OK) ou passe 3
  - NOM + typevoie + nomvoie + compvoie + codpost + ville — Table de référence : geo.corvilleparCLECOMPLETE — → ficvilleok3 (OK) ou validation manuelle
- Étape 1.3 — Validation manuelle de la ville
  - Recherche la bonne villenorm en s'aidant du compvoie, du nom, de Google Maps
  - Attribue un TYPERAP (type de rapprochement)
    - 1 = ville trouvée via l'adresse seule (cas général : erreur CP ou coquille)
    - 2 = ville trouvée uniquement grâce au nom complet de l'établissement
    - 4 = forçage (fusions de communes, quartiers devenus communes)

    Après import : Les corrections alimentent geo.corvilleparadr → Ce tables grossisse chaque année, réduisant le volume de validation manuelle
    - 3 = ville trouvée via Street View, quasi certaine

    Après import : Les corrections alimentent geo.corvilleparCLECOMPLETE → Ce tables grossisse chaque année, réduisant le volume de validation manuelle
    - ETR = établissement à l'étranger → supprimé
- Étape 1.4 — Boucle de contrôle — Le sous-programme est relancé : la table validmanuelleville4 doit être vide (0 enregistrements). Si non vide, il faut corriger et recommencer. — Sortie : &ficinit.OK — table avec un champ villenorm validé pour chaque enregistrement.

Phase 2 — Correction des codes postaux

But : S'assurer que la combinaison codpost + villenorm existe dans le référentiel postal officiel.

- Étape 2.1 — Rapprochement automatique en 3 passes
  - codpost + villenorm — Table de référence : geo.listevillenorm — → CPok (OK) ou passe 2
  - Rapprochement par nom de voie — Table de référence : geo.Hexavia_voieexport (base La Poste) — CPok2 (OK) ou passe 3
  - Rapprochement via geo.TablecorCPn_1 (corrections manuelles accumulées) — → CPok3 (OK) ou CPfaux3 (à corriger)
- Étape 2.2 — Correction automatique des cas simples — Pour les villes ayant un seul code postal dans geo.listevillenorm, le bon CP est attribué automatiquement.
- Étape 2.3 — Validation manuelle des CP — CPfaux3 est exporté en Excel (Validation_CP.xlsx) — validateur
  - Remplit codpostH (code postal Hexavia corrigé) en cherchant sur Google Maps
  - Peut aussi corriger villenorm si l'adresse correspond en fait à une autre ville

  Après import : Les corrections alimentent geo.TablecorCPn_1
- Étape 2.4 — Contrôle final des CP — Un test vérifie que toute combinaison codpost + villenorm existe dans geo.listevillenorm. Si des cas subsistent (ptbListevillenorm2) — export/import/correction jusqu'à résolution. — Sortie : &ficinit avec codpost et villenorm validés et cohérents.

Phase 3 — Géocodage commune (attribution du code INSEE)

But : Attribuer le codinsee (code commune INSEE) et le nom commune officiel à chaque enregistrement.

- Étape 3.0 — Préparation
  - Suppression des territoires hors France (Saint-Barthélemy, Saint-Martin, Nouvelle-Calédonie, etc.) — → Table de référence : table _HFR
  - Corrections manuelles spécifiques (Orly, Paray-Vieille-Poste, etc.)
- Étape 3.1 — Séparation Paris / Lyon-Marseille / Reste
  - Paris (20 arrondissements)
  - Lyon (9) et Marseille (16)

  Ils ont un seul code postal pour plusieurs communes INSEE (arrondissements). Le géocodage nécessite un traitement spécial par rue.
  - Reste (tous les autres)
- Étape 3.2 — Géocodage du « Reste » — 4 passes de rapprochement successives contre la table CPIM (référentiel INSEE)
  - codpost + clevil (ville normalisée nettoyée) — Match direct CP+commune
  - dep + clevil — Match par département (pour les CP erronés résiduels)
  - Via CorrespVillenorm_Com.xlsx — Table de correspondance manuelle villenorm → commune
  - Match élargi dep + clevil avec les correspondances — Dernière tentative
  - Les cas non résolus — → ValidGeomanuelle — → pause validation manuelle.
- Étape 3.3 — Géocodage de Paris / Lyon / Marseille (Partie 2) — Pour ces 3 villes, le codinsee (arrondissement) est déterminé par le code postal :
  - Paris — CP 75001→75020 → codinsee 75101→75120
  - Lyon — CP 69001→69009 → codinsee 69381→69389
  - Marseille — CP 13001→13016 → codinsee 13201→13216

  Vérification que tous les codinsee attribués sont valides (pas de 75000, pas de 69000, etc.).
- Étape 3.4 — Assemblage final (Partie 3)
  - Fusion des 3 flux (Reste + Paris + Lyon/Marseille) → &ficout
  - Recalcul du département depuis codinsee
  - Suppression des variables de travail
  - Vérification : PB_FIN (codinsee vide) doit être vide
  - Contrôle : nobsinit = nobsfin (aucun enregistrement perdu)

Sortie finale → &ficin.G (ex: RESTO_2025_01_75ADROKG) : table géocodée au niveau commune, prête pour l'étape 3 (géocodage XY).

Presented with xmind