Dernière mise à jour: 02-04-2026

Un pipeline de normalisation et validation d'adresses postales

- **1- Traitement Adresse**
  - Étape 0 — Consolidation des sources
0- Préparation de la table contenant toutes les adresses des OGR.sas
    - rassemble les adresses provenant de multiples sources
      - Pages Jaunes
      - TripadVisor
  - Étape 1 — Traitement automatique (« Appelé 1 »)
Appelé 1-Traitement adresse.sas
    - orchestre ~21 macros enchaînées qui découpent une adresse brute (champ texte unique)
      - Program sas : MacroAdr1
        - Nettoyage des caractères spéciaux et accents
      - Program sas : MacroAdr2
        - Extraction du code postal et de la ville
      - Program sas : MacroAdr3
        - Normalisation des expressions courantes
      - Program sas : MacroAdr4/5
        - Normalisation BP (boîte postale) et CP
      - Program sas : MacroAdr6
        - Normalisation du type de voie (RUE, AVENUE...)
      - Program sas : MacroAdr7
        - Traitement des CEDEX
      - Program sas : MacroAdr8/9
        - Extraction des zones (ZAC, ZI, centre commercial...)
      - Program sas : MacroAdr12-18
        - Extraction du numéro de voie, BIS/TER, type de voie
      - Program sas : MacroAdr21
        - Suppression des espaces multiples
      - Résultat
        - l'adresse brute "12 BIS RUE VICTOR HUGO 75001 PARIS"
          - est éclatée en → numvoie=12, compvoie=BIS, typevoie=RUE, nomvoie=VICTOR HUGO, codpost=75001, ville=PARIS
  - Étape 2 — Corrections manuelles connues (« Appelé 2 »)
Appelé 2- Correction séparation auto vues précedemment.sas
    - applique des corrections cas par cas — des adresses mal découpées identifiées les années précédentes
      - base de connaissances des erreurs connues
        - 1. Corrections « en dur » cas par cas
          - 5 grandes familles d'erreurs corrigées
            - Ville polluée
              - ville="1 R VASCO DE GAMA 44955 NANTES"
                - On redistribue : numvoie="1", typevoie="RUE", nomvoie="VASCO DE GAMA", codpost="44955", ville="NANTES"
            - Nom de voie trop long (contient un complément collé)
              - nomvoie="JEAN JAURES L ORANGERIE"
                - On coupe : nomvoie="JEAN JAURES", compvoie="L ORANGERIE"
            - Type de voie absorbé dans le nom
              - nomvoie="R AMIRAL COURBET"
                - On extrait : typevoie="RUE", nomvoie="AMIRAL COURBET"
            - Code postal / ville mélangés
              - ville="35517 CESSON SEVIGNE"
                - On sépare : codpost="35517", ville="CESSON SEVIGNE"
            - Fautes d'orthographe
              - nomvoie="CHARLES DE GAULE"
                - → "CHARLES DE GAULLE"
        - 2. Nettoyages semi-génériques
        - 3. Macros de vérification
          - appelle des macros de contrôle
macro1_7a à macro1_7f
            - Le numvoie ne contient-il pas de texte parasite (ex: 32RR) ?
            - Le nomvoie contient-il encore un type de voie non extrait ?
            - typevoie vide alors que numvoie rempli → incohérence ?
            - typevoie vide → cas à investiguer
            - nomvoie contient des mots comme « AGENCE », « SALLE COURRIER » → à nettoyer
  - Étape 3 — Validation manuelle
1- Traitement adresse auto et vérification des adresses - Fichiers BAN.sas
    - Phase 1 - Génère une clé unique par adresse (cle = dep + compvoie + codpost + ville + numvoie + typevoie + nomvoie)
      - 75CIMMEUBLE APOLLO75001PARIS12TRUEVICTOR HUGO
        - → c'est l'identité unique de cette adresse découpée
    - Phase 2 - Compare avec la table ValidManAdrExtracOK (corrections manuelles déjà validées)
      - Un MERGE par clé sépare les adresses en deux flux
        - Adress auto valide : ADRAutoOK
          - Clé trouvée dans l'historique
          - Adresse déjà validée une année précédente
            - → on réutilise la correction
        - Adress à valide manuellement : AdrManuel
          - Clé absente de l'historique
          - Adresse nouvelle
            - → à envoyer en validation manuelle
        - C'est le mécanisme d'apprentissage cumulatif : chaque année, le volume à valider manuellement diminue car les corrections s'accumulent.
    - Phase 3 - Sépare en ADRAutoOK (déjà validées) et AdrManuel (à valider manuellement)
      - Export pour validation humaine
        - La table AdrManuel est enrichie avec le nom de l'agence (pour aider le validateur) puis exportée en Excel
          - Le fichier contient les colonnes de l'adresse découpée automatiquement + 6 colonnes vides pour les corrections :
            - Colonnes auto (lecture seule)
              - numvoie, typevoie, nomvoie, compvoie, codpost, ville
            - Colonnes manuelles (à remplir)
              - numvoie2, typevoie2, nomvoie2, compvoie2, codpost2, ville2
    - Phase 4 - PAUSE : Validation humaine
      - Surligner en jaune les lignes où codpost ou ville sont vides
      - Pour corriger un champ
        - remplir la colonne *2 correspondante (ex: nomvoie2)
      - Pour vider un champ → écrire "VIDE" dans la colonne *2
      - Pour supprimer une ligne (pas une adresse) → mettre "VIDE" dans nomvoie2
      - Points de vigilance
        - 1 - Vérifier que numvoie ne contient pas de texte parasite
        - 2 - Le codpost doit faire exactement 5 chiffres
        - 3 - La ville doit être remplie pour tout le monde
        - 4 - Si nomvoie contient encore un complément collé → le séparer dans compvoie2
        - 5 - Attention aux numéros de voie très grands (souvent suspects)
      - Le fichier validé est sauvegardé sous
        - ValidManAdrExtractionOK.xlsx.
    - Phase 5 - Réimport et fusion
      - Import du fichier Excel validé
      - Re-merge avec toutes les adresses pour appliquer les corrections
      - Application des corrections :
        - si *2 contient une valeur → elle remplace le champ original ; si *2 = "VIDE" → le champ est vidé ; si nomvoie2 = "VIDE" → la ligne est supprimée
      - Nettoyage final : suppression des adresses sans nom de voie, des adresses en Andorre, recalcul du département
- **2- Géocodage commune**