Un pipeline de normalisation et validation d'adresses postales

Dernière mise à jour: 08-04-2026

1- Traitement Adresse

Étape 0 — Consolidation des sources

0- Préparation de la table contenant toutes les adresses des OGR.sas

rassemble les adresses provenant de multiples sources

- Pages Jaunes
- TripadVisor

Étape 1 — Traitement automatique (« Appelé 1 »)

Appelé 1-Traitement adresse.sas

orchestre ~21 macros enchaînées qui découpent une adresse brute (champ texte unique)

- Program sas : MacroAdr1 — Nettoyage des caractères spéciaux et accents
  - Les accents sont retirés (é→e, ç→c, ô→o, etc.)
  - Tous les symboles deviennent des espaces : - , _ „ /, (,), @, :, ', ", etc.
  - Mise en MAJUSCULES
  - Suppression des espaces multiples
  - AVANT : "12, Bd Victor-Hugo — 75016 PARIS Cedex" APRÈS : "12 BD VICTOR HUGO 75016 PARIS CEDEX"
- Program sas : MacroAdr2 — Extraction du code postal et de la ville
  - AVANT : "12 BD VICTOR HUGO 75016 PARIS" APRÈS : adresse="12 BD VICTOR HUGO" | codpost="75016" | ville="PARIS"
- Program sas : MacroAdr3 — Normalisation des expressions courantes
  - La plus grosse étape. Elle standardise des centaines d'abréviations et de variantes
    - Abréviations courantes → RESID→RESIDENCE, FBG→FAUBOURG, BAT→BATIMENT, LOT→LOTISSEMENT, LD→LIEU DIT
    - Case postale → C P, C.P. → CP
    - Zones industrielles → Z I, Z.A.C, Z. A. E → ZI, ZAC, ZAE
    - Espaces commerciaux → GAL COM → GALERIE COMMERCIALE
    - Centres commerciaux → CTRE CIAL, CC, CCIAL, C CIAL → CENTRE COMMERCIAL
    - Galeries marchandes → GAL MARCHANDE, GALE MARCH → GALERIE MARCHANDE
    - Grades militaires → GEN→GENERAL, LT→LIEUTENANT, CDT→COMMANDANT, DR→DOCTEUR
    - Présidents → PRES→PRESIDENT, PDT→PRESIDENT + corrections noms (MITERRAND→MITTERRAND)
    - Unités militaires → RI=Régiment d'Infanterie, DB=Division Blindée + ordinaux (1 ER→1ER)
    - Noms de rues célèbres → DE LATTE→DE LATTRE DE TASSIGNY, MAL FOCH→MARECHAL FOCH
    - Saints → SAINT→ST, SAINTE→STE
  - Résultat → l'adresse brute "12 BIS RUE VICTOR HUGO 75001 PARIS" → est éclatée en → numvoie=12, compvoie=BIS, typevoie=RUE, nomvoie=VICTOR HUGO, codpost=75001, ville=PARIS
- Program sas : MacroAdr4/5 — Normalisation BP (boîte postale) et CP
- Program sas : MacroAdr6 — Normalisation du type de voie (RUE, AVENUE...)
- Program sas : MacroAdr7 — Traitement des CEDEX
- Program sas : MacroAdr8/9 — Extraction des zones (ZAC, ZI, centre commercial...)
- Program sas : MacroAdr12-18 — Extraction du numéro de voie, BIS/TER, type de voie
- Program sas : MacroAdr21 — Suppression des espaces multiples

Étape 2 — Corrections manuelles connues (« Appelé 2 »)

Appelé 2- Correction séparation auto vues précedemment.sas

applique des corrections cas par cas — des adresses mal découpées identifiées les années précédentes

base de connaissances des erreurs connues

1. Corrections « en dur » cas par cas — 5 grandes familles d'erreurs corrigées
   - Ville polluée → ville="1 R VASCO DE GAMA 44955 NANTES" → On redistribue : numvoie="1", typevoie="RUE", nomvoie="VASCO DE GAMA", codpost="44955", ville="NANTES"
   - Nom de voie trop long (contient un complément collé) → nomvoie="JEAN JAURES L ORANGERIE" → On coupe : nomvoie="JEAN JAURES", compvoie="L ORANGERIE"
   - Type de voie absorbé dans le nom → nomvoie="R AMIRAL COURBET" → On extrait : typevoie="RUE", nomvoie="AMIRAL COURBET"
   - Code postal / ville mélangés → ville="35517 CESSON SEVIGNE" → On sépare : codpost="35517", ville="CESSON SEVIGNE"
   - Fautes d'orthographe → nomvoie="CHARLES DE GAULE" → "CHARLES DE GAULLE"
2. Nettoyages semi-génériques
3. Macros de vérification — appelle des macros de contrôle macro1_7a à macro1_7f
   - Le numvoie ne contient-il pas de texte parasite (ex: 32RR) ?
   - Le nomvoie contient-il encore un type de voie non extrait ?
   - typevoie vide alors que numvoie rempli → incohérence ?
   - typevoie vide → cas à investiguer
   - nomvoie contient des mots comme « AGENCE », « SALLE COURRIER » → à nettoyer

Étape 3 — Validation manuelle

1- Traitement adresse auto et vérification des adresses - Fichiers BAN.sas

- Phase 1 - Génère une clé unique par adresse (cle = dep + compvoie + codpost + ville + numvoie + typevoie + nomvoie) — Cle = compress(dep||"C"||compvoie||codpost||ville||numvoie||"T"||typevoie||"N"||nomvoie||adresseecompl); → c'est l'identité unique de cette adresse découpée
  - 75CIMMEUBLE APOLLO75001PARIS12TRUEVICTOR HUGO
- Phase 2 - Compare avec la table ValidManAdrExtracOK (corrections manuelles déjà validées) — Un MERGE par clé sépare les adresses en deux flux
  - Adress auto valide : ADRAutoOK
    - Clé trouvée dans l'historique
    - Adresse déjà validée une année précédente → on réutilise la correction
  - Adress à valide manuellement : AdrManuel
    - Clé absente de l'historique
    - Adresse nouvelle → à envoyer en validation manuelle
  - C'est le mécanisme d'apprentissage cumulatif : chaque année, le volume à valider manuellement diminue car les corrections s'accumulent.
- Phase 3 - Sépare en ADRAutoOK (déjà validées) et AdrManuel (à valider manuellement) — Export pour validation humaine — La table AdrManuel est enrichie avec le nom de l'agence (pour aider le validateur) puis exportée en Excel — Le fichier contient les colonnes de l'adresse découpée automatiquement + 6 colonnes vides pour les corrections :
  - Colonnes auto (lecture seule) → numvoie, typevoie, nomvoie, compvoie, codpost, ville
  - Colonnes manuelles (à remplir) → numvoie2, typevoie2, nomvoie2, compvoie2, codpost2, ville2
- Phase 4 - PAUSE : Validation humaine
  - Surligner en jaune les lignes où codpost ou ville sont vides
  - Pour corriger un champ → remplir la colonne *2 correspondante (ex: nomvoie2)
  - Pour vider un champ → écrire "VIDE" dans la colonne *2
  - Pour supprimer une ligne (pas une adresse) → mettre "VIDE" dans nomvoie2
  - Points de vigilance
    1. Vérifier que numvoie ne contient pas de texte parasite
    2. Le codpost doit faire exactement 5 chiffres
    3. La ville doit être remplie pour tout le monde
    4. Si nomvoie contient encore un complément collé → le séparer dans compvoie2
    5. Attention aux numéros de voie très grands (souvent suspects)
  - Le fichier validé est sauvegardé sous → ValidManAdrExtractionOK.xlsx.
- Phase 5 - Réimport et fusion
  - Import du fichier Excel validé
  - Re-merge avec toutes les adresses pour appliquer les corrections
  - Application des corrections : → si *2 contient une valeur → elle remplace le champ original ; si *2 = "VIDE" → le champ est vidé ; si nomvoie2 = "VIDE" → la ligne est supprimée
  - Nettoyage final : suppression des adresses sans nom de voie, des adresses en Andorre, recalcul du département

INPUT (champ texte brut unique) → "12 BIS R VICTOR HUGO CTR COM LECLERC 75001 PARIS"

- MacroAdr2 : extrait codpost, ville
- MacroAdr6 : R → RUE
- MacroAdr8/9: isole CENTRE COMMERCIAL
- MacroAdr12: crée numvoie/nomvoie
- MacroAdr17: isole BIS/TER
- MacroAdr18: extrait typevoie

OUTPUT (champs structurés séparés)

- numvoie → 12
- typevoie → RUE
- nomvoie → VICTOR HUGO
- compvoie → CENTRE COMMERCIAL LECLERC
- codpost → 75001
- ville → PARIS

2- Géocodage commune

Phase 1 — Normalisation de la ville (villenorm)

Transformer le champ ville (saisi/extrait, avec erreurs) en un champ villenorm correspondant à un nom de commune officiel.

Étape 1.1 — Préparation

- Création du champ NOM (nom de l'établissement) pour aider aux rapprochements
- Nettoyage du champ ville via %macroAdr1 (suppression accents, symboles)
- Suppression de cas étrangers (Luxembourg, Suisse, Allemagne, Andorre)
- Suppression des adresses vides ou avec dep="98" (Monaco, étranger)

Étape 1.2 — Rapprochement automatique en 3 passes

- codpost + villevalid (ville avec ST/STE) — Table de référence : geo.listevillenorm → → ficvilleok (OK) ou passe 2
- typevoie + nomvoie + compvoie + codpost + ville — Table de référence geo.corvilleparadr → → ficvilleok2 (OK) ou passe 3
- NOM + typevoie + nomvoie + compvoie + codpost + ville — Table de référence : geo.corvilleparCLECOMPLETE → → ficvilleok3 (OK) ou validation manuelle

Étape 1.3 — Validation manuelle de la ville

Recherche la bonne villenorm en s'aidant du compvoie, du nom, de Google Maps

Attribue un TYPERAP (type de rapprochement)

- 1 = ville trouvée via l'adresse seule (cas général : erreur CP ou coquille)
- 2 = ville trouvée uniquement grâce au nom complet de l'établissement
- 4 = forçage (fusions de communes, quartiers devenus communes)

Après import : Les corrections alimentent geo.corvilleparadr → Ce tables grossisse chaque année, réduisant le volume de validation manuelle

- 3 = ville trouvée via Street View, quasi certaine

Après import : Les corrections alimentent geo.corvilleparCLECOMPLETE → Ce tables grossisse chaque année, réduisant le volume de validation manuelle

- ETR = établissement à l'étranger → supprimé

Étape 1.4 — Boucle de contrôle

Le sous-programme est relancé : la table validmanuelleville4 doit être vide (0 enregistrements). Si non vide, il faut corriger et recommencer.

Sortie : &ficinit.OK — table avec un champ villenorm validé pour chaque enregistrement.

Phase 2 — Correction des codes postaux

But : S'assurer que la combinaison codpost + villenorm existe dans le référentiel postal officiel.

Étape 2.1 — Rapprochement automatique en 3 passes

- codpost + villenorm — Table de référence : geo.listevillenorm → → CPok (OK) ou passe 2
- Rapprochement par nom de voie — Table de référence : geo.Hexavia_voieexport (base La Poste) → CPok2 (OK) ou passe 3
- Rapprochement via geo.TablecorCPn_1 (corrections manuelles accumulées) → → CPok3 (OK) ou CPfaux3 (à corriger)

Étape 2.2 — Correction automatique des cas simples

Pour les villes ayant un seul code postal dans geo.listevillenorm, le bon CP est attribué automatiquement.

Étape 2.3 — Validation manuelle des CP

CPfaux3 est exporté en Excel (Validation_CP.xlsx) — validateur

- Remplit codpostH (code postal Hexavia corrigé) en cherchant sur Google Maps
- Peut aussi corriger villenorm si l'adresse correspond en fait à une autre ville

Après import : Les corrections alimentent geo.TablecorCPn_1

Étape 2.4 — Contrôle final des CP

Un test vérifie que toute combinaison codpost + villenorm existe dans geo.listevillenorm. Si des cas subsistent (pbListevillenorm2) — export/import/correction jusqu'à résolution. → Sortie : &ficinit avec codpost et villenorm validés et cohérents.

Phase 3 — Géocodage commune (attribution du code INSEE)

But : Attribuer le codinsee (code commune INSEE) et le nom commune officiel à chaque enregistrement.

Étape 3.0 — Préparation

- Suppression des territoires hors France (Saint-Barthélemy, Saint-Martin, Nouvelle-Calédonie, etc.) → Table de référence : table _HFR
- Corrections manuelles spécifiques (Orly, Paray-Vieille-Poste, etc.)

Étape 3.1 — Séparation Paris / Lyon-Marseille / Reste

- Paris (20 arrondissements)
- Lyon (9) et Marseille (16)

Ils ont un seul code postal pour plusieurs communes INSEE (arrondissements). Le géocodage nécessite un traitement spécial par rue.

- Reste (tous les autres)

Étape 3.2 — Géocodage du « Reste »

4 passes de rapprochement successives contre la table CPM (référentiel INSEE)

- codpost + clevil (ville normalisée nettoyée) → Match direct CP+commune
- dep + clevil → Match par département (pour les CP erronés résiduels)
- Via CorrespVillenorm_Com.xlsx → Table de correspondance manuelle villenorm → commune
- Match élargi dep + clevil avec les correspondances → Dernière tentative
- Les cas non résolus → → ValidGeomanuelle → → pause validation manuelle.

Étape 3.3 — Géocodage de Paris / Lyon / Marseille (Partie 2)

Pour ces 3 villes, le codinsee (arrondissement) est déterminé par le code postal :

- Paris → CP 75001→75120 → codinsee 75101→75120
- Lyon → CP 69001→69009 → codinsee 69381→69389
- Marseille → CP 13001→13016 → codinsee 13201→13216

Vérification que tous les codinsee attribués sont valides (pas de 75000, pas de 69000, etc.).

Étape 3.4 — Assemblage final (Partie 3)

- Fusion des 3 flux (Reste + Paris + Lyon/Marseille) → &ficout
- Recalcul du département depuis codinsee
- Suppression des variables de travail
- Vérification : PB_FIN (codinsee vide) doit être vide
- Contrôle : nobsinit = nobsfin (aucun enregistrement perdu)

Sortie finale → &ficin.G (ex: RESTO_2025_01_75ADROK0) : table géocodée au niveau commune, prête pour l'étape 3 (géocodage XY).

Presented with xmind