BD-Resto: Un pipeline de normalisation et validation d'adresses postales: Resumé

1- Traitement Adresse

- INPUT (champ texte brut unique) — "12 BIS R VICTOR HUGO CTR COM LECLERC 75001 PARIS"
  - MacroAdr2 : extrait codpost, ville
  - MacroAdr6 : R → RUE
  - MacroAdr8/9: isole CENTRE COMMERCIAL
  - MacroAdr12: crée numvoie/nomvoie
  - MacroAdr17: isole BIS/TER
  - MacroAdr18: extrait typevoie
  - OUTPUT (champs structurés séparés)
    - numvoie — 12
    - typevoie — RUE
    - nomvoie — VICTOR HUGO
    - compvoie — CENTRE COMMERCIAL LECLERC
    - codpost — 75001
    - ville — PARIS

2- Géocodage commune

Résoudre le problème des fusions de communes et de l'instabilité géographique française pour attribuer à chaque point de vente le code commune INSEE officiel et actuel, seul identifiant géographique stable utilisable pour le géocodage XY.

- INPUT (issu de l'étape 1) codpost="49160" ville="LONGUE"
- [Normalisation ville] villevalid = codpost + "LONGUE" → pas dans LISTEVILLENORM
- [macroCORvillenorm2018] "LONGUE" + CP "49160" → villenorm = "LONGUE JUMELLES" ← fusion connue
- [Rapprochement CPIM] clé: dep="49" + clevil="LONGUEJUMELLES" → COMMUNE="LONGUE JUMELLES" CODINSEE="49181" ✓
- OUTPUT codpost="49160" villenorm="LONGUE JUMELLES" COMMUNE="LONGUE JUMELLES" CODINSEE="49181"

Presented with xmind