Import et normalisation des adresses

Extraire les données brutes depuis les bases PostgreSQL (4 sources différentes), les fusionner, faire un nettoyage initial et les préparer pour le géocodage.

4 Sources

1. Source PJ (Pages Jaunes / Justadapt)
   - Base PostgreSQL : infostatmut_validation_ogrx.scrap.pj_restauration_f
   - Flag : source="PJ"
   - Colonnes extraites : id, adresse, activite, ambiance, budget, denomination, prestation, siren, siret, site, tel, type_cuisine, departement
2. Source TA (TripAdvisor)
   - Base PostgreSQL : infostatmut_validation_ogrx.scrap.tripadvisor
   - Colonnes extraites : id, adresse, fonctionalite, fourchette_prix, horaires, nom_restaurant, note, regime_speciaux, repas, telephone, type_cuisine
   - Flag : source="TA"
3. Source STOCK (SIRENE actifs)
   - Base PostgreSQL : geosirene.poi.sirene_etablissement_n0_sans_geo
   - Flag : source="STOCK"
   - Création id : *n* (numéro de ligne, car SIRENE n'a pas d'ID natif)
4. Source FERM (SIRENE fermés)
   - data sasdon.ferm_adr_2024_12_44;
   - Flag : source="FERM"
   - Création id : *n* (numéro de ligne, car SIRENE n'a pas d'ID natif)

Fusion des 4 sources

- Nettoyage : Suppression du mot "France" ou "FRANCE" à la fin de l'adresse
- Suppression des lignes sans adresse : if adresse="" then delete;
- Normalisation de la dénomination
  - PJ : denomination
  - TA : nom_restaurant
  - STOCK : denomination_geoscar
  - FERM : priorité à denomination_geoscar, sinon denominationusuelleetablissement, sinon enseigne1etablissement

→ denomination_f

Presented with xmind