OGR_RESTO

Rapprocher les nouvelles données de restaurants (N) avec la base existante (N-1) pour créer des groupes de fiches identiques et attribuer un niveau de confiance.

1. Import et fusion

- l'étape traitement adresse a déjà été exécutée
  - produit deux tables distinctes
    - données brutes complètes (toutes colonnes métier)
      - RESTO_2025_01_75
      - colonnes métier
        - denomination_f
        - activite
        - ambiance
        - budget
        - prestation
        - type_cuisine
        - site
        - ...
    - données avec adresses validées par le géocodeur (uniquement colonnes d'adresse)
      - RESTO_2025_01_75ADROKOKG
- Le but est de fusionner ces deux tables pour obtenir une seule table contenant à la fois les adresses validées ET toutes les informations métier.
- Éléments critiques
  - Clés de jointure
    - source + id
      - source : PJ / TA / STOCK / FERM
      - id : identifiant unique au sein de chaque source

2. Nettoyage

Cette étape transforme les données brutes/géocodées en données exploitables pour le rapprochement, en normalisant et nettoyant tous les champs textuels.

- Nettoyage des accents et caractères spéciaux
  - Champs traités :
    - Adresse : nomvoie, compvoie
    - Métier : denomination_f, prestation, type_cuisine, fonctionalite, regime_speciaux, repas
  - Résumé
    - U:\Production\Referentiel GEO POI\1-Traitement Adresse\sasprog\macros
    - transformations standardisées
      - République → REPUBLIQUE — Suppression accents + majuscules
      - Saint-Denis → SAINT-DENIS — Normalisation casse
      - L'Oasis → L OASIS — Normalisation apostrophes
      - Café André → CAFE ANDRE — Accents supprimés
      - Brasserie n°12 BRASSERIE N 12 — Caractères spéciaux normalisés
- Suppression des espaces dans nomvoie et compvoie
  - JEAN JAURES -> JEANJAURES
  - VICTOIRE -> VICTOIRE
  - CHARLES DE GAULLE -> CHARLESDEGAULLE
  - Pourquoi supprimer les espaces ?
    - Variabilité des sources :
      - PJ : "JEAN JAURES"
      - TA : "JEAN JAURES" (double espace)
      - STOCK : "JEANJAURES" (sans espace)
      - BAN : "JEAN JAURES" (espace simple)
    - Clés de rapprochement : les clés sont construites par concaténation
      - les espaces perturbent la comparaison
        - Sans suppression : "REPUBLIQUE" + "JEAN JAURES" = "REPUBLIQUEJEAN JAURES"
        - Avec suppression : "REPUBLIQUE" + "JEANJAURES" = "REPUBLIQUEJEANJAURES"
- Nettoyage des doublons nomvoie/compvoie
  - Complément identique au nom de voie
    - Avant : nomvoie="REPUBLIQUE", compvoie="REPUBLIQUE"
    - Après : nomvoie="REPUBLIQUE", compvoie=""
  - Nom de voie vide mais complément rempli
    - Avant : nomvoie="", compvoie="VICTOIRE"
    - Après : nomvoie="VICTOIRE", compvoie=""
  - Évite la redondance dans la clé : REPUBLIQUEREPUBLIQUE devient REPUBLIQUE
- Suppression des prépositions en début de voie
  - DE LA / DE L / DU / DES / DE / D
  - en cas de 'DE GAULLE' ou 'DE LATTRE DE'
    - NON MODIFIÉ (exception)
      - DE GAULLE : c'est un nom propre, pas une préposition
      - DE LATTRE DE : idem (Général de Lattre de Tassigny)
  - Exemples concrets :
    - DE LA REPUBLIQUE -> REPUBLIQUE — Suppression "DE LA " (6 car)
    - DU GENERAL LECLERC -> GENERAL LECLERC — Suppression "DU " (3 car)
    - DE LA PAIX -> PAIX — Suppression "DE " (3 car)
    - DE GAULLE -> DE GAULLE — NON MODIFIÉ (exception)
    - DE LATTRE DE TASSIGNY -> DE LATTRE DE TASSIGNY — NON MODIFIÉ (exception)
  - Pourquoi ?
    - Variabilité des sources
      - PJ : "RUE REPUBLIQUE"
      - TA : "RUE DE LA REPUBLIQUE"
      - STOCK : "RUE DE LA REPUBLIQUE"
      - BAN : "R DE LA REPUBLIQUE"
    - Normalisation : après traitement, toutes deviennent "REPUBLIQUE" → facilite le rapprochement
- Nettoyage de la dénomination
  - compresse les espaces multiples en un seul
  - supprime espaces de fin
  - Suppression du nom de ville dans la dénomination
    - Vérifier si le nom de ville est dans la dénomination
    - Extraire le mot AVANT la ville
    - Vérifier si ce mot est une préposition
    - Cas de suppression :
      - RESTAURANT LYON — RESTAURANT — "RESTAURANT" n'est pas une prépo — c'est une indication de spécialité culinaire, pas une localisation
      - PIZZERIA MARSEILLE — PIZZERIA — "PIZZERIA" n'est pas une prépo
      - BRASSERIE DE PARIS — BRASSERIE DE PARIS — "DE" est une prépo → CONSERVÉ — c'est le nom de l'établissement
      - AUBERGE DU VILLAGE MONTMARTRE — AUBERGE DU VILLAGE MONTMARTRE — "DU" est une prépo → CONSERVÉ
  - Suppression des lignes avec "ND ND"
    - ND = "Non Déterminé" ou "Non Défini"
    - Valeur par défaut parfois retournée par le géocodeur BAN quand l'adresse est introuvable ou ambiguë
    - nomvoie = "ND ND RUE PRINCIPALE" → SUPPRIMÉ
    - nomvoie = "VICTOIRE" → CONSERVÉ

4. Dédoublonnage par score

5. Rapprochement avec N-1 "pas gardées" et "fermées"

6. Rapprochement avec N-1 "validées"

7. Séparation par source

8. Rapprochement inverse (N-1 → N)

9. Création des codens (identifiants de regroupement)

10. Attribution couleur de confiance

11. Rapprochement avec SIRENE fermés

12. Contrôles avancés (5 programmes annexes)

13. Export

Presented with xmind