# OGR_RESTO

Rapprocher les nouvelles données de restaurants (N) avec la base existante (N-1) pour créer des groupes de fiches identiques et attribuer un niveau de confiance.

## 1. Import et fusion

- l'étape traitement adresse a déjà été exécutée
  - produit deux tables distinctes
    - données brutes complètes (toutes colonnes métier)
      - RESTO_2025_01_75
      - colonnes métier
        - denomination_f
        - activite
        - ambiance
        - budget
        - prestation
        - type_cuisine
        - site
        - ...
    - données avec adresses validées par le géocodeur (uniquement colonnes d'adresse)
      - RESTO_2025_01_75ADROKOKG

Le but est de fusionner ces deux tables pour obtenir une seule table contenant à la fois les adresses validées ET toutes les informations métier.

- Éléments critiques
  - Clés de jointure
    - source + id
      - source : PJ / TA / STOCK / FERM
      - id : identifiant unique au sein de chaque source

## 2. Nettoyage

Cette étape transforme les données brutes/géocodées en données exploitables pour le rapprochement, en normalisant et nettoyant tous les champs textuels.

- Nettoyage des accents et caractères spéciaux
  - Champs traités :
    - Adresse : nomvoie, compvoie
    - Métier : denomination_f, prestation, type_cuisine, fonctionalite, regime_speciaux, repas

Résumé

- U:\Production\Referentiel GEO PO\1-Traitement Adresse\sasprog\macros
- transformations standardisées
  - République → REPUBLIQUE → Suppression accents + majuscules
  - Saint-Denis → SAINT-DENIS → Normalisation casse
  - L'Oasis → L OASIS → Normalisation apostrophes
  - Café André → CAFE ANDRE → Accents supprimés
  - Brasserie n°12 → BRASSERIE N 12 → Caractères spéciaux normalisés

- Suppression des espaces dans nomvoie et compvoie
  - JEAN JAURES -> JEANJAURES
  - VICTOIRE -> VICTOIRE
  - CHARLES DE GAULLE -> CHARLESDEGAULLE

Pourquoi supprimer les espaces ?

- Variabilité des sources :
  - PJ : "JEAN JAURES"
  - TA : "JEAN JAURES" (double espace)
  - STOCK : "JEANJAURES" (sans espace)
  - BAN : "JEAN JAURES" (espace simple)
- Clés de rapprochement : les clés sont construites par concaténation
  - les espaces perturbent la comparaison
    - Sans suppression : "REPUBLIQUE" + "JEAN JAURES" = "REPUBLIQUEJEAN JAURES"
    - Avec suppression : "REPUBLIQUE" + "JEANJAURES" = "REPUBLIQUEJEANJAURES"

- Nettoyage des doublons nomvoie/compvoie
  - Complément identique au nom de voie
    - Avant : nomvoie="REPUBLIQUE", compvoie="REPUBLIQUE"
    - Après : nomvoie="REPUBLIQUE", compvoie=""
  - Nom de voie vide mais complément rempli
    - Avant : nomvoie="", compvoie="VICTOIRE"
    - Après : nomvoie="VICTOIRE", compvoie=""

Évite la redondance dans la clé : REPUBLIQUEREPUBLIQUE devient REPUBLIQUE

- Suppression des prépositions en début de voie
  - DE LA / DE L / DU / DES / DE / D
  - en cas de 'DE GAULLE' ou 'DE LATTRE DE'
    - NON MODIFIÉ (exception)
      - DE GAULLE : c'est un nom propre, pas une préposition
      - DE LATTRE DE : idem (Général de Lattre de Tassigny)
  - Exemples concrets :
    - DE LA REPUBLIQUE -> REPUBLIQUE → Suppression "DE LA " (6 car)
    - DU GENERAL LECLERC -> GENERAL LECLERC → Suppression "DU " (3 car)
    - DE LA PAIX -> PAIX → Suppression "DE " (3 car)
    - DE GAULLE -> DE GAULLE → NON MODIFIÉ (exception)
    - DE LATTRE DE TASSIGNY -> DE LATTRE DE TASSIGNY → NON MODIFIÉ (exception)

Pourquoi ?

- Variabilité des sources
  - PJ : "RUE REPUBLIQUE"
  - TA : "RUE DE LA REPUBLIQUE"
  - STOCK : "RUE DE LA REPUBLIQUE"
  - BAN : "R DE LA REPUBLIQUE"
- Normalisation : après traitement, toutes deviennent "REPUBLIQUE" → facilite le rapprochement

- Nettoyage de la dénomination
  - compresse les espaces multiples en un seul
  - supprime espaces de fin
  - Suppression du nom de ville dans la dénomination
    - Vérifier si le nom de ville est dans la dénomination
    - Extraire le mot AVANT la ville
    - Vérifier si ce mot est une préposition
  - Suppression des lignes avec "ND ND"
    - ND = "Non Déterminé" ou "Non Défini"
    - Valeur par défaut parfois retournée par le géocodeur BAN quand l'adresse est introuvable ou ambiguë
    - nomvoie = "ND ND RUE PRINCIPALE" → SUPPRIMÉ
    - nomvoie = "VICTOIRE" → CONSERVÉ

Cas de suppression :

- RESTAURANT LYON → RESTAURANT → "RESTAURANT" n'est pas une prépo → c'est une indication de spécialité culinaire, pas une localisation
- PIZZERIA MARSEILLE → PIZZERIA → "PIZZERIA" n'est pas une prépo
- BRASSERIE DE PARIS → BRASSERIE DE PARIS → "DE" est une prépo → CONSERVÉ → c'est le nom de l'établissement
- AUBERGE DU VILLAGE MONTMARTRE → AUBERGE DU VILLAGE MONTMARTRE → "DU" est une prépo → CONSERVÉ

## 3. Création des clés de rapprochement

1. Cette étape est cruciale : elle crée 10 clés différentes par fiche, permettant de détecter les doublons même quand l'information est partielle ou légèrement différente.

- Calcul du dernier mot de la voie
- Les 10 clés de rapprochement
  - cle_complete → denomination_f‖numvoie‖typevoie‖nomvoie‖compvoie‖codpost‖villenorm → ★★★★★ Match parfait
  - cle_complete2 → denomination_f‖numvoie‖typevoie‖last_mot_voie‖compvoie‖codpost‖villenorm → ★★★★ Voie abrégée
  - cle_pcompl → denomination_f‖numvoie‖typevoie‖nomvoie‖codpost‖villenorm → ★★★★ Sans complément
  - cle_pcompl2 → denomination_f‖numvoie‖typevoie‖last_mot_voie‖codpost‖villenorm → ★★★ Voie abrégée sans compl
  - cle_comp_ss_num → denomination_f‖typevoie‖nomvoie‖compvoie‖codpost‖villenorm → ★★★ Sans n° de voie
  - cle_pcompl_ss_num → denomination_f‖typevoie‖nomvoie‖codpost‖villenorm → ★★ Sans n° ni compl
  - cle_pcompl2_ss_num → denomination_f‖typevoie‖last_mot_voie‖codpost‖villenorm → ★★ La plus large avec denom
  - cle_adr_complete → numvoie‖typevoie‖nomvoie‖compvoie‖codpost‖villenorm → ★★★ Adresse seule
  - cle_adr_pcomp → numvoie‖typevoie‖nomvoie‖codpost‖villenorm → ★★ Adresse sans compl
  - cle_adr_pcomp2 → numvoie‖typevoie‖last_mot_voie‖codpost‖villenorm → ★ Adresse la plus souple
- exemple (10)
- Pourquoi 10 clés et pas une seule ?
  - Problème : les données sont hétérogènes et incomplètes
    - PJ
      - Qualité adresse ★★★★
      - Qualité dénomination ★★★★
    - TA
      - Qualité adresse ★★★
      - Qualité dénomination ★★★★★
    - STOCK
      - Qualité adresse ★★★★★
      - Qualité dénomination ★★
    - FERM
      - Qualité adresse ★★★★
      - Qualité dénomination ★
- Exemples de variations réelles :
  - Source PJ : "RESTAURANT L'OASIS", "15 RUE REPUBLIQUE BAT A", "75011", "PARIS"
  - Source TA : "L'Oasis", "15 rue de la République", "75011", "Paris 11e"
  - Source STOCK : "L OASIS", "15 R REPUBLIQUE", "75011", "PARIS"
  - Source BAN : "OASIS", "15 RUE DE LA REPUBLIQUE", "75011", "PARIS"

Après nettoyage :

- PJ : denom="RESTAURANTLOASIS", numvoie="15", typevoie="RUE", nomvoie="REPUBLIQUE", compvoie="BATA"
- TA : denom="LOASIS", numvoie="15", typevoie="RUE", nomvoie="REPUBLIQUE", compvoie=""
- STOCK : denom="LOASIS", numvoie="15", typevoie="R", nomvoie="REPUBLIQUE", compvoie=""
- BAN : denom="OASIS", numvoie="15", typevoie="RUE", nomvoie="REPUBLIQUE", compvoie=""

Résultat

- Sans les 10 clés → → 4 fiches séparées (aucun match)
- Avec les 10 clés :
  - cle_complete : ❌ Aucun match (trop strict)
  - cle_pcompl : ❌ Aucun match
  - cle_pcompl_ss_num : ❌ Aucun match (dénominations différentes)
  - cle_adr_pcomp : ✅ Match sur les 4 fiches (adresse seule, sans dénomination)
- → Les 4 fiches sont regroupées et un validateur humain confirme qu'il s'agit du même établissement.

- Cas d'usage des différentes clés
  - Scénario 1 : Fiche identique
    - Fiche A (PJ) : LE BISTROT, 12 RUE REPUBLIQUE BAT A, 75011 PARIS → cle_complete = "LEBISTROT12RUEREPUBLIQUEBATA75011PARIS"
    - Fiche B (TA) : LE BISTROT, 12 RUE REPUBLIQUE BAT A, 75011 PARIS → cle_complete = "LEBISTROT12RUEREPUBLIQUEBATA75011PARIS"

    Résultat → ✅ Match sur cle_complete → → Confiance maximale (couleur = 1)
  - Scénario 2 : Complément manquant
    - Fiche A (PJ) : LE BISTROT, 12 RUE REPUBLIQUE BAT A, 75011 PARIS → cle_pcompl = "LEBISTROT12RUEREPUBLIQUE75011PARIS"
    - Fiche B (STOCK) : LE BISTROT, 12 RUE REPUBLIQUE, 75011 PARIS (pas de complément) → cle_pcompl = "LEBISTROT12RUEREPUBLIQUE75011PARIS"

    Résultat → ✅ Match sur cle_pcompl → → Très haute confiance (couleur = 1)
  - Scénario 3 : Numéro de voie manquant
    - Fiche A (PJ) : LE BISTROT, 12 RUE REPUBLIQUE, 75011 PARIS → cle_pcompl_ss_num = "LEBISTROTRUEREPUBLIQUE75011PARIS"
    - Fiche B (TA) : LE BISTROT, RUE REPUBLIQUE, 75011 PARIS (pas de numéro) → cle_pcompl_ss_num = "LEBISTROTRUEREPUBLIQUE75011PARIS"

    Résultat → ✅ Match sur cle_pcompl_ss_num → → Bonne confiance (couleur = 2)
  - Scénario 4 : Nom légèrement différent
    - Fiche A (PJ) : LE BISTROT, 12 RUE REPUBLIQUE, 75011 PARIS → cle_adr_pcomp = "12RUEREPUBLIQUE75011PARIS"
    - Fiche B (STOCK) : LE BISTROT PARISIEN, 12 RUE REPUBLIQUE, 75011 PARIS (nom différent) → cle_adr_pcomp = "12RUEREPUBLIQUE75011PARIS"

    Résultat → ✅ Match sur cle_adr_pcomp (adresse seule) → → À vérifier (couleur = 3)
  - Scénario 5 : Nom de voie abrégé
    - Fiche A (BAN) : LE BISTROT, 12 RUE GENERAL DE GAULLE, 75011 PARIS → nomvoie = "GENERALDEGAULLE" → last_mot_voie = "GAULLE" → cle_pcompl2 = "LEBISTROT12RUEGAULLE75011PARIS"
    - Fiche B (TA) : LE BISTROT, 12 RUE DE GAULLE, 75011 PARIS (version abrégée) → nomvoie = "DEGAULLE" (préposition "DE" conservée car "DE GAULLE") → last_mot_voie = "GAULLE" → cle_pcompl2 = "LEBISTROT12RUEGAULLE75011PARIS"

    Résultat → ✅ Match sur cle_pcompl2 → → Haute confiance (couleur = 1)
  - Scénario 6 : Centre commercial (même adresse, plusieurs restos)
    - Fiche A : PIZZERIA NAPOLI, 5 PLACE VICTOR HUGO, 75016 PARIS → cle_adr_complete = "5PLACEVICTORHUGO75016PARIS"
    - Fiche B : SUSHI KING, 5 PLACE VICTOR HUGO, 75016 PARIS (autre resto, même adresse) → cle_adr_complete = "5PLACEVICTORHUGO75016PARIS"

    Résultat → ⚠️ Match sur cle_adr_complete mais noms différents → → Validation manuelle requise (couleur = 3)
- Stratégie de rapprochement en cascade
  - Le programme utilise les clés dans l'ordre de précision :
    - Essaye cle_complete → si match, confiance maximale ✅
    - Sinon cle_complete2 → si match, très haute confiance ✅
    - Sinon cle_pcompl → si match, haute confiance ✅
    - Sinon cle_comp_ss_num → si match, bonne confiance ⚠️
    - Sinon cle_pcompl2_ss_num → si match, à vérifier ⚠️
    - Sinon cle_adr_* → si match, validation manuelle requise ⚠️ ⚠️
    - Sinon → nouvelle fiche, validation manuelle requise ⚠️ ⚠️ ⚠️

## 4. Dédoublonnage par score

## 5. Rapprochement avec N-1 "pas gardées" et "fermées"

## 6. Rapprochement avec N-1 "validées"

## 7. Séparation par source

## 8. Rapprochement inverse (N-1 → N)

## 9. Création des codens (identifiants de regroupement)

## 10. Attribution couleur de confiance

## 11. Rapprochement avec SIRENE fermés

## 12. Contrôles avancés (5 programmes annexes)

## 13. Export

Presented with xmind