OGR_RESTO

Rapprocher les nouvelles données de restaurants (N) avec la base existante (N-1) pour créer des groupes de fiches identiques et attribuer un niveau de confiance.

Dérnière mise à jour: 16-04-2026

1. Import et fusion

- l'étape traitement adresse a déjà été exécutée
  - produit deux tables distinctes
    - données brutes complètes (toutes colonnes métier)
      - RESTO_2025_01_75
      - colonnes métier
        - denomination_f
        - activite
        - ambiance
        - budget
        - prestation
        - type_cuisine
        - site
        - ...
    - données avec adresses validées par le géocodeur (uniquement colonnes d'adresse)
      - RESTO_2025_01_75ADROKOKG

Le but est de fusionner ces deux tables pour obtenir une seule table contenant à la fois les adresses validées ET toutes les informations métier.

- Éléments critiques
  - Clés de jointure
    - source + id
      - source : PJ / TA / STOCK / FERM
      - id : identifiant unique au sein de chaque source

2. Nettoyage

Cette étape transforme les données brutes/géocodées en données exploitables pour le rapprochement, en normalisant et nettoyant tous les champs textuels.

- Nettoyage des accents et caractères spéciaux
  - Champs traités :
    - Adresse : nomvoie, compvoie
    - Métier : denomination_f, prestation, type_cuisine, fonctionalite, regime_speciaux, repas
  - Résumé
    - U:\Production\Referentiel GEO PO\1-Traitement Adresse\sasprog\macros
    - transformations standardisées
      - République → REPUBLIQUE — Suppression accents + majuscules
      - Saint-Denis → SAINT-DENIS — Normalisation casse
      - L'Oasis → L OASIS — Normalisation apostrophes
      - Café André → CAFE ANDRE — Accents supprimés
      - Brasserie n°12 BRASSERIE N 12 — Caractères spéciaux normalisés
- Suppression des espaces dans nomvoie et compvoie
  - JEAN JAURES -> JEANJAURES
  - VICTOIRE -> VICTOIRE
  - CHARLES DE GAULLE -> CHARLESDEGAULLE
  - Pourquoi supprimer les espaces ?
    - Variabilité des sources :
      - PJ : "JEAN JAURES"
      - TA : "JEAN JAURES" (double espace)
      - STOCK : "JEANJAURES" (sans espace)
      - BAN : "JEAN JAURES" (espace simple)
    - Clés de rapprochement : les clés sont construites par concaténation
      - les espaces perturbent la comparaison
        - Sans suppression : "REPUBLIQUE" + "JEAN JAURES" = "REPUBLIQUEJEAN JAURES"
        - Avec suppression : "REPUBLIQUE" + "JEANJAURES" = "REPUBLIQUEJEANJAURES"
- Nettoyage des doublons nomvoie/compvoie
  - Complément identique au nom de voie
    - Avant : nomvoie="REPUBLIQUE", compvoie="REPUBLIQUE"
    - Après : nomvoie="REPUBLIQUE", compvoie=""
  - Nom de voie vide mais complément rempli
    - Avant : nomvoie="", compvoie="VICTOIRE"
    - Après : nomvoie="VICTOIRE", compvoie=""

Évite la redondance dans la clé : REPUBLIQUEREPUBLIQUE devient REPUBLIQUE

- Suppression des prépositions en début de voie
  - DE LA / DE L / DU / DES / DE / D
  - en cas de 'DE GAULLE' ou 'DE LATTRE DE'
    - NON MODIFIÉ (exception)
      - DE GAULLE : c'est un nom propre, pas une préposition
      - DE LATTRE DE : idem (Général de Lattre de Tassigny)
  - Exemples concrets :
    - DE LA REPUBLIQUE -> REPUBLIQUE — Suppression "DE LA " (6 car)
    - DU GENERAL LECLERC -> GENERAL LECLERC — Suppression "DU " (5 car)
    - DE LA PAIX -> PAIX — Suppression "DE " (3 car)
    - DE GAULLE -> DE GAULLE — NON MODIFIÉ (exception)
    - DE LATTRE DE TASSIGNY -> DE LATTRE DE TASSIGNY — NON MODIFIÉ (exception)
  - Pourquoi ?
    - Variabilité des sources
      - PJ : "RUE REPUBLIQUE"
      - TA : "RUE DE LA REPUBLIQUE"
      - STOCK : "RUE DE LA REPUBLIQUE"
      - BAN : "R DE LA REPUBLIQUE"
    - Normalisation : après traitement, toutes deviennent "REPUBLIQUE" → facilite le rapprochement
- Nettoyage de la dénomination
  - compresse les espaces multiples en un seul
  - supprime espaces de fin
  - Suppression du nom de ville dans la dénomination
    - Vérifier si le nom de ville est dans la dénomination
    - Extraire le mot AVANT la ville
    - Vérifier si ce mot est une préposition
    - Cas de suppression :
      - RESTAURANT LYON — RESTAURANT — "RESTAURANT" n'est pas une prépo — c'est une indication de spécialité culinaire, pas une localisation
      - PIZZERIA MARSEILLE — PIZZERIA — "PIZZERIA" n'est pas une prépo
      - BRASSERIE DE PARIS — BRASSERIE DE PARIS — "DE" est une prépo → CONSERVÉ — c'est le nom de l'établissement
      - AUBERGE DU VILLAGE MONTMARTRE / AUBERGE DU VILLAGE MONTMARTRE — "DU" est une prépo → CONSERVÉ
  - Suppression des lignes avec "ND ND"
    - ND = "Non Déterminé" ou "Non Défini"
    - Valeur par défaut parfois retournée par le géocodeur BAN quand l'adresse est introuvable ou ambiguë
    - nomvoie = "ND ND RUE PRINCIPALE" → SUPPRIMÉ
    - nomvoie = "VICTOIRE" → CONSERVÉ

3. Création des clés de rapprochement

1. Cette étape est cruciale : elle crée 10 clés différentes par fiche, permettant de détecter les doublons même quand l'information est partielle ou légèrement différente.

- Calcul du dernier mot de la voie
- Les 10 clés de rapprochement
  - cle_complete — denomination_f‖numvoie‖typevoie‖nomvoie‖compvoie‖codpost‖villenorm — ★★★★★ Match parfait
  - cle_complete2 — denomination_f‖numvoie‖typevoie‖last_mot_voie‖compvoie‖codpost‖villenorm — ★★★★ Voie abrégée
  - cle_pcompl — denomination_f‖numvoie‖typevoie‖nomvoie‖codpost‖villenorm — ★★★★ Sans complément
  - cle_pcompl2 — denomination_f‖numvoie‖typevoie‖last_mot_voie‖codpost‖villenorm — ★★★ Voie abrégée sans compl
  - cle_comp_ss_num — denomination_f‖typevoie‖nomvoie‖compvoie‖codpost‖villenorm — ★★★ Sans n° de voie
  - cle_pcompl_ss_num — denomination_f‖typevoie‖nomvoie‖codpost‖villenorm — ★★ Sans n° ni compl
  - cle_pcompl2_ss_num — denomination_f‖typevoie‖last_mot_voie‖codpost‖villenorm — ★★ La plus large avec denom
  - cle_adr_complete — numvoie‖typevoie‖nomvoie‖compvoie‖codpost‖villenorm — ★★★ Adresse seule
  - cle_adr_pcomp — numvoie‖typevoie‖nomvoie‖codpost‖villenorm — ★★ Adresse sans compl
  - cle_adr_pcomp2 — numvoie‖typevoie‖last_mot_voie‖codpost‖villenorm — ★ Adresse la plus souple
- exemple
- Pourquoi 10 clés et pas une seule ?
  - Problème : les données sont hétérogènes et incomplètes
    - PJ
      - Qualité adresse — ★★★★
      - Qualité dénomination — ★★★★
    - TA
      - Qualité adresse — ★★★
      - Qualité dénomination — ★★★★★
    - STOCK
      - Qualité adresse — ★★★★★
      - Qualité dénomination — ★★
    - FERM
      - Qualité adresse — ★★★★
      - Qualité dénomination — ★
- Exemples de variations réelles :
  - Source PJ : "RESTAURANT L'OASIS", "15 RUE REPUBLIQUE BAT A", "75011", "PARIS"
  - Source TA : "L'Oasis", "15 rue de la République", "75011", "Paris 11e"
  - Source STOCK : "L OASIS", "15 R REPUBLIQUE", "75011", "PARIS"
  - Source BAN : "OASIS", "15 RUE DE LA REPUBLIQUE", "75011", "PARIS"
  - Après nettoyage :
    - PJ : denom="RESTAURANTLOASIS", numvoie="15", typevoie="RUE", nomvoie="REPUBLIQUE", compvoie="BATA"
    - TA : denom="LOASIS", numvoie="15", typevoie="RUE", nomvoie="REPUBLIQUE", compvoie=""
    - STOCK : denom="LOASIS", numvoie="15", typevoie="R", nomvoie="REPUBLIQUE", compvoie=""
    - BAN : denom="OASIS", numvoie="15", typevoie="RUE", nomvoie="REPUBLIQUE", compvoie=""
  - Résultat
    - Sans les 10 clés → 4 fiches séparées (aucun match)
    - Avec les 10 clés :
      - cle_complete : ❌ Aucun match (trop strict)
      - cle_pcompl : ❌ Aucun match
      - cle_pcompl_ss_num : ❌ Aucun match (dénominations différentes)
      - cle_adr_pcomp : ✅ Match sur les 4 fiches (adresse seule, sans dénomination)
    - → Les 4 fiches sont regroupées et un validateur humain confirme qu'il s'agit du même établissement.
- Cas d'usage des différentes clés
- Stratégie de rapprochement en cascade
  - Le programme utilise les clés dans l'ordre de précision :
    - Essaye cle_complete → si match, confiance maximale ✅
    - Sinon cle_complete2 → si match, très haute confiance ✅
    - Sinon cle_pcompl → si match, haute confiance ✅
    - Sinon cle_comp_ss_num → si match, bonne confiance ⚠️
    - Sinon cle_pcompl2_ss_num → si match, à vérifier ⚠️
    - Sinon cle_adr_* → si match, validation manuelle requise ⚠️⚠️
    - Sinon → nouvelle fiche, validation manuelle requise ⚠️⚠️⚠️

4. Dédoublonnage par score

Cette étape résout un problème critique : pour une même clé de rapprochement, on peut avoir plusieurs lignes avec des niveaux de complétude différents. Il faut choisir la ligne la plus riche en informations.

- 4.1 — Le problème : doublons avec informations partielles
  - Exemple concret
    - Après l'étape 3, on peut avoir cette situation :
      - PJ
        - id — 101
        - denomination_f — LEBISTROT
        - cle_complete — LEBISTROT12RUE_PARIS
        - activite — Restaurant
        - ambiance — Convivial
        - budget — €€
        - type_cuisine — Français
        - telephone — 0145678901
        - site — bistrot.fr
      - TA
        - id — 205
        - denomination_f — LEBISTROT
        - cle_complete — LEBISTROT12RUE_PARIS
        - activite
        - ambiance — Chaleureux
        - budget
        - type_cuisine — Français, Européen
        - telephone
        - site
      - STOCK
        - id — 876
        - denomination_f — LEBISTROT
        - cle_complete — LEBISTROT12RUE_PARIS
        - activite
        - ambiance
        - budget
        - type_cuisine
        - telephone
        - site
    - Résumé
      - Les 3 lignes ont la même cle_complete → c'est le même restaurant
      - Mais elles ont des informations complémentaires différentes
      - Question : laquelle garder ?
        - laquelle garder ?
- 4.2 — La solution : calcul d'un score de complétude
  - Étape A : Calcul du score
    - La macro parcourt les champs spécifiés et compte combien sont non vides :
      - nb_remp
  - Étape B : Tri par score décroissant
  - Étape C : Suppression des doublons
    - on ne conserve que la première ligne de chaque groupe, c'est-à-dire celle avec le score le plus élevé.
- 4.3 — Pourquoi c'est crucial ?
  - Problème 1 : Redondance d'informations
    - Sans ce dédoublonnage, on aurait 3 lignes pour "Le Bistrot" qui seraient ensuite traitées séparément dans les rapprochements → multiplication par 3 du volume de données à traiter.
  - Problème 2 : Perte d'information dans les étapes suivantes
    - Les étapes ultérieures (rapprochement avec N-1, agrégation par codens) fonctionnent mieux avec une seule ligne de référence par clé.
  - Problème 3 : Qualité de validation
    - LE BISTROT - PJ - 12 RUE REPUBLIQUE - 0145678901 - bistrot.fr
    - LE BISTROT - TA - 12 RUE REPUBLIQUE - (pas de tel) - (pas de site)
    - LE BISTROT - STOCK - 12 RUE REPUBLIQUE - (pas de tel) - (pas de site)

5. Rapprochement avec N-1 "pas gardées" et "fermées"

6. Rapprochement avec N-1 "validées"

7. Séparation par source

8. Rapprochement inverse (N-1 → N)

9. Création des codens (identifiants de regroupement)

10. Attribution couleur de confiance

11. Rapprochement avec SIRENE fermés

12. Contrôles avancés (5 programmes annexes)

13. Export

Presented with xmind