OGR_RESTO

Dérnière mise à jour: 16-04-2026

Rapprocher les nouvelles données de restaurants (N) avec la base existante (N-1) pour créer des groupes de fiches identiques et attribuer un niveau de confiance.

1. Import et fusion

- L'étape traitement adresse a déjà été exécutée
  - produit deux tables distinctes
    - données brutes complètes (toutes colonnes métier)
      - RESTO_2025_01_75
      - colonnes métier
        - denomination_f
        - activite
        - ambiance
        - budget
        - prestation
        - type_cuisine
        - site
        - _
    - données avec adresses validées par le géocodeur (uniquement colonnes d'adresse)
      - RESTO_2025_01_75ADROKOKG
    - Le but est de fusionner ces deux tables pour obtenir une seule table contenant à la fois les adresses validées ET toutes les informations métier.
- Éléments critiques
  - Clés de jointure
    - source + id
      - source : PJ / TA / STOCK / FERM
      - id : identifiant unique au sein de chaque source

2. Nettoyage

Cette étape transforme les données brutes/géocodées en données exploitables pour le rapprochement, en normalisant et nettoyant tous les champs textuels.

- Nettoyage des accents et caractères spéciaux
  - Champs traités :
    - Adresse : nomvoie, compvoie
    - Métier : denomination_f, prestation, type_cuisine, fonctionalite, regime_speciaux, repas
    - Résumé
      - U:\Production\Referentiel GEO POI\1-Traitement Adresse\sasprog\macros
      - transformations standardisées
        - République   REPUBLIQUE Suppression accents + majuscules
        - Saint-Denis   SAINT-DENIS Normalisation casse
        - L'Oasis   L OASIS Normalisation apostrophes
        - Café André   CAFE ANDRE Accents supprimés
        - Brasserie n°12 BRASSERIE N 12   Caractères spéciaux normalisés
- Suppression des espaces dans nomvoie et compvoie
  - JEAN JAURES -> JEANJAURES
  - VICTOIRE -> VICTOIRE
  - CHARLES DE GAULLE -> CHARLESDEGAULLE
  - Pourquoi supprimer les espaces ?
    - Variabilité des sources :
      - PJ : "JEAN JAURES"
      - TA : "JEAN JAURES" (double espace)
      - STOCK : "JEANJAURES" (sans espace)
      - BAN : "JEAN JAURES" (espace simple)
    - Clés de rapprochement : les clés sont construites par concaténation
      - les espaces perturbent la comparaison
        - Sans suppression : "REPUBLIQUE" + "JEAN JAURES" = "REPUBLIQUEJEAN JAURES"
        - Avec suppression : "REPUBLIQUE" + "JEANJAURES" = "REPUBLIQUEJEANJAURES"
- Nettoyage des doublons nomvoie/compvoie
  - Complément identique au nom de voie
    - Avant : nomvoie="REPUBLIQUE", compvoie="REPUBLIQUE"
    - Après : nomvoie="REPUBLIQUE", compvoie=""
    - Évite la redondance dans la clé : REPUBLIQUEREPUBLIQUE devient REPUBLIQUE
  - Nom de voie vide mais complément rempli
    - Avant : nomvoie="", compvoie="VICTOIRE"
    - Après : nomvoie="VICTOIRE", compvoie=""
- Suppression des prépositions en début de voie
  - DE LA / DE L / DU / DES / DE / D
  - en cas de 'DE GAULLE' ou 'DE LATTRE DE'
    - NON MODIFIÉ (exception)
      - DE GAULLE : c'est un nom propre, pas une préposition
      - DE LATTRE DE : idem (Général de Lattre de Tassigny)
  - Exemples concrets :
    - DE LA REPUBLIQUE -> REPUBLIQUE — Suppression "DE LA " (6 car)
    - DU GENERAL LECLERC -> GENERAL LECLERC — Suppression "DU " (3 car)
    - DE LA PAIX -> PAIX — Suppression "DE " (3 car)
    - DE GAULLE -> DE GAULLE — NON MODIFIÉ (exception)
    - DE LATTRE DE TASSIGNY -> DE LATTRE DE TASSIGNY — NON MODIFIÉ (exception)
  - Pourquoi ?
    - Variabilité des sources
      - PJ : "RUE REPUBLIQUE"
      - TA : "RUE DE LA REPUBLIQUE"
      - STOCK : "RUE DE LA REPUBLIQUE"
      - BAN : "R DE LA REPUBLIQUE"
    - Normalisation : après traitement, toutes deviennent "REPUBLIQUE" → facilite le rapprochement
- Nettoyage de la dénomination
  - compresse les espaces multiples en un seul
  - supprime espaces de fin
  - Suppression du nom de ville dans la dénomination
    - Vérifier si le nom de ville est dans la dénomination
    - Extraire le mot AVANT la ville
    - Vérifier si ce mot est une préposition
    - Cas de suppression :
      - RESTAURANT LYON   RESTAURANT — "RESTAURANT" n'est pas une prépo — c'est une indication de spécialité culinaire, pas une localisation
      - PIZZERIA MARSEILLE   PIZZERIA — "PIZZERIA" n'est pas une prépo
      - BRASSERIE DE PARIS   BRASSERIE DE PARIS — "DE" est une prépo → CONSERVÉ — c'est le nom de l'établissement
      - AUBERGE DU VILLAGE MONTMARTRE AUBERGE DU VILLAGE MONTMARTRE — "DU" est une prépo → CONSERVÉ
  - Suppression des lignes avec "ND ND"
    - ND = "Non Déterminé" ou "Non Défini"
    - Valeur par défaut parfois retournée par le géocodeur BAN quand l'adresse est introuvable ou ambiguë
    - nomvoie = "ND ND RUE PRINCIPALE" → SUPPRIMÉ
    - nomvoie = "VICTOIRE" → CONSERVÉ

3. Création des clés de rapprochement

1. Cette étape est cruciale : elle crée 10 clés différentes par fiche, permettant de détecter les doublons même quand l'information est partielle ou légèrement différente.

- Calcul du dernier mot de la voie
- Les 10 clés de rapprochement
  - cle_complete — denomination_f||numvoie||typevoie||nomvoie||compvoie||codpost||villenorm — ★★★★★ Match parfait
  - cle_complete2 — denomination_f||numvoie||typevoie||last_mot_voie||compvoie||codpost||villenorm — ★★★★ Voie abrégée
  - cle_pcompl — denomination_f||numvoie||typevoie||nomvoie||codpost||villenorm — ★★★★ Sans complément
  - cle_pcompl2 — denomination_f||numvoie||typevoie||last_mot_voie||codpost||villenorm — ★★★ Voie abrégée sans compl
  - cle_comp_ss_num — denomination_f||typevoie||nomvoie||compvoie||codpost||villenorm — ★★★ Sans n° de voie
  - cle_pcompl_ss_num — denomination_f||typevoie||nomvoie||codpost||villenorm — ★★ Sans n° ni compl
  - cle_pcompl2_ss_num — denomination_f||typevoie||last_mot_voie||codpost||villenorm — ★★ La plus large avec denom
  - cle_adr_complete — numvoie||typevoie||nomvoie||compvoie||codpost||villenorm — ★★★ Adresse seule
  - cle_adr_pcomp — numvoie||typevoie||nomvoie||codpost||villenorm — ★★ Adresse sans compl
  - cle_adr_pcomp2 — numvoie||typevoie||last_mot_voie||codpost||villenorm — ★ Adresse la plus souple
- exemple
- Pourquoi 10 clés et pas une seule ?
  - Problème : les données sont hétérogènes et incomplètes
    - PJ
      - Qualité adresse ★★★★
      - Qualité dénomination ★★★★
    - TA
      - Qualité adresse ★★★
      - Qualité dénomination ★★★★★
    - STOCK
      - Qualité adresse ★★★★★
      - Qualité dénomination ★★
    - FERM
      - Qualité adresse ★★★★
      - Qualité dénomination ★
- Exemples de variations réelles :
  - Source PJ   : "RESTAURANT L'OASIS", "15 RUE REPUBLIQUE BAT A", "75011", "PARIS"
  - Source TA   : "L'Oasis", "15 rue de la République", "75011", "Paris 11e"
  - Source STOCK : "L OASIS", "15 R REPUBLIQUE", "75011", "PARIS"
  - Source BAN   : "OASIS", "15 RUE DE LA REPUBLIQUE", "75011", "PARIS"
  - Après nettoyage :
    - PJ   : denom="RESTAURANTLOASIS", numvoie="15", typevoie="RUE", nomvoie="REPUBLIQUE", compvoie="BATA"
    - TA   : denom="LOASIS", numvoie="15", typevoie="RUE", nomvoie="REPUBLIQUE", compvoie=""
    - STOCK : denom="LOASIS", numvoie="15", typevoie="R", nomvoie="REPUBLIQUE", compvoie=""
    - BAN   : denom="OASIS", numvoie="15", typevoie="RUE", nomvoie="REPUBLIQUE", compvoie=""
    - Résultat
      - Sans les 10 clés — → 4 fiches séparées (aucun match)
      - Avec les 10 clés :
        - cle_complete : ❌ Aucun match (trop strict)
        - cle_pcompl : ❌ Aucun match
        - cle_pcompl_ss_num : ❌ Aucun match (dénominations différentes)
        - cle_adr_pcomp : ✅ Match sur les 4 fiches (adresse seule, sans dénomination)
      - → Les 4 fiches sont regroupées et un validateur humain confirme qu'il s'agit du même établissement.
- Cas d'usage des différentes clés
- Stratégie de rapprochement en cascade
  - Le programme utilise les clés dans l'ordre de précision :
    - Essaye cle_complete → si match, confiance maximale ✅
    - Sinon cle_complete2 → si match, très haute confiance ✅
    - Sinon cle_pcompl → si match, haute confiance ✅
    - Sinon cle_comp_ss_num → si match, bonne confiance ⚠️
    - Sinon cle_pcompl2_ss_num → si match, à vérifier ⚠️
    - Sinon cle_adr_* → si match, validation manuelle requise ⚠️ ⚠️
    - Sinon → nouvelle fiche, validation manuelle requise ⚠️ ⚠️ ⚠️

4. Dédoublonnage par score

Cette étape résout un problème critique : pour une même clé de rapprochement, on peut avoir plusieurs lignes avec des niveaux de complétude différents. Il faut choisir la ligne la plus riche en informations.

- 4.1 — Le problème : doublons avec informations partielles
  - Exemple concret
    - Après l'étape 3, on peut avoir cette situation :

	PJ	TA	STOCK
id	101	205	876
denomination_f	LEBISTROT	LEBISTROT	LEBISTROT
cle_complete	LEBISTROT12RUE_PARIS	LEBISTROT12RUE_PARIS	LEBISTROT12RUE_PARIS
activite	Restaurant		
ambiance	Convivial	Chaleureux	
budget	€€		
type_cuisine	Français	Français, Européen	
telephone	0145678901		
site	bistrot.fr		

- Résumé
  - Les 3 lignes ont la même cle_complete → c'est le même restaurant
  - Mais elles ont des informations complémentaires différentes
  - Question : laquelle garder ? — laquelle garder ?
- 4.2 — La solution : calcul d'un score de complétude
  - Étape A : Calcul du score
    - La macro parcourt les champs spécifiés et compte combien sont non vides :
      - nb_remp
  - Étape B : Tri par score décroissant
  - Étape C : Suppression des doublons
    - on ne conserve que la première ligne de chaque groupe, c'est-à-dire celle avec le score le plus élevé.
- 4.3 — Pourquoi c'est crucial ?
  - Problème 1 : Redondance d'informations
    - Sans ce dédoublonnage, on aurait 3 lignes pour "Le Bistrot" qui seraient ensuite traitées séparément dans les rapprochements → multiplication par 3 du volume de données à traiter.
  - Problème 2 : Perte d'information dans les étapes suivantes
    - Les étapes ultérieures (rapprochement avec N-1, agrégation par codens) fonctionnent mieux avec une seule ligne de référence par clé.
  - Problème 3 : Qualité de validation
    - LE BISTROT - PJ - 12 RUE REPUBLIQUE - 0145678901 - bistrot.fr
    - LE BISTROT - TA - 12 RUE REPUBLIQUE - (pas de tel) - (pas de site)
    - LE BISTROT - STOCK - 12 RUE REPUBLIQUE - (pas de tel) - (pas de site)
  - 4.6 — Cas particuliers et subtilités
    - Cas 1 : Égalité de score
      - Résultat : La première dans l'ordre de tri est gardée (ici, PJ car by source id initial)
      - Impact : Si PJ et TA ont des infos différentes mais même score, on perd les infos de TA → c'est une limite du système
    - Cas 2 : Champs vides vs espaces
    - Cas 3 : Qualité vs quantité
      - PJ : 10 champs remplis mais type_cuisine — = "Restaurant" (générique)
      - TA : 3 champs remplis mais type_cuisine — = "Cuisine française, bistronomique, produits locaux" (précis)
      - Problème : PJ est gardé (score 10) mais son info est moins qualitative que TA (score 3)
  - 4.7 — Limites et compromis
    - Limite 1 : Perte d'informations complémentaires
      - Si source A a telephone et source B a site, mais même score → on perd une des deux infos.
      - Mitigation : L'étape 2 récupère ces infos via agrégation par codens.
    - Limite 2 : Biais en faveur de certaines sources
    - Limite 3 : Ne détecte pas les doublons avec clés différentes
      - Si deux fiches ont cle_complete différentes (ex: faute de frappe dans le nom), elles ne sont pas dédoublonnées.
      - Mitigation : C'est le rôle des 10 clés (étape 3) et de la création des codens (étape ultérieure).

5. Rapprochement avec N-1 "pas gardées" et "fermées"

Cette étape identifie les fiches de l'extraction N qui correspondent à des établissements déjà écartés ou fermés lors de la campagne précédente (N-1).

- Objectif : éviter de les revalider inutilement.
  - 5.1 — Contexte et objectif
    - Situation :
      - La campagne N-1 a déjà validé des milliers de fiches
      - Certaines ont été marquées "pas gardées" : doublons, adresses erronées, non-restaurants...
      - D'autres ont été marquées "fermées" : établissements disparus, radiés...
    - Problème :
      - Ces fiches peuvent réapparaître dans les nouvelles extractions N
      - PJ/TA n'ont pas mis à jour leurs bases
      - SIRENE contient toujours l'établissement fermé
    - Solution :
      - Rapprocher les extractions N avec les fiches rejetées N-1 pour :
        - ✅ Gagner du temps : pas de revalidation manuelle
        - ✅ Cohérence temporelle : un resto fermé en 2022 a peu de chances d'être rouvert en 2025
        - ⚠️ Alerte : si une fiche "fermée N-1" réapparaît dans PJ/TA → peut-être une réouverture à vérifier
  - 5.2 — Rapprochement avec "pas gardées"
    - Étape 5.2.1 — Création des clés N-1
      - Recalcule les 10 clés de rapprochement :
      - Pourquoi recalculer les clés ?
        - Les données N-1 peuvent avoir un format légèrement différent (version SAS antérieure)
        - Les règles de nettoyage ont pu évoluer
        - Garantit la compatibilité entre N et N-1
      - Résultat :
        - Table temporaire PAS_GARDES_N1 avec ~500 à 2000 fiches rejetées en N-1, avec leurs 10 clés de rapprochement.
    - Étape 5.2.2 — Rapprochement en cascade (6 passes)
    - Étape 5.2.3 — Les 6 passes successives
      - Chaque passe utilise une clé différente, de la plus stricte à la plus large :
        - 1 cle_complete — ★★★★★ Fiche exactement identique
        - 2 cle_complete2 — ★★★★ Nom de voie légèrement différent
        - 3 cle_pcompl — ★★★★ Complément d'adresse manquant
        - 4 cle_comp_ss_num — ★★★ Numéro de voie manquant
        - 5 cle_pcompl2 — ★★★ Variante nom voie + sans compl
        - 6 cle_pcompl2_ss_num — ★★ La plus large (sans n° ni compl)
    - Étape 5.2.4 — Exemple concret
      - Fiche rejetée en 2022 :
        - denomination_f = "SNACKDUCOINDRUE"
        - numvoie = "8"
        - typevoie = "RUE"
        - nomvoie = "VICTOIRE"
        - codpost = "75009"
        - villenorm = "PARIS"
        - → cle_complete = "SNACKDUCOINDRUE8RUEVICTOIRE75009PARIS"
        - → cle_pcompl2_ss_num = "SNACKDUCOINDRUEVICTOIRE75009PARIS"
        - Motif rejet — → : "Pas un restaurant, c'est un kebab ambulant"
      - Fiche PJ 2025 :
        - denomination_f = "SNACKDUCOINDRUE"
        - numvoie = "" ← PAS DE NUMÉRO
        - typevoie = "RUE"
        - nomvoie = "VICTOIRE"
        - codpost = "75009"
        - villenorm = "PARIS"
        - → cle_complete = "SNACKDUCOINDRUERUEVICTOIRE75009PARIS"
        - → cle_pcompl2_ss_num = "SNACKDUCOINDRUEVICTOIRE75009PARIS" ← MATCH !
      - Rapprochement
        - 1 cle_complete — ❌ Non (numéro différent) pas_garde_n1 reste vide
        - 2 cle_complete2 — ❌ Non pas_garde_n1 reste vide
        - 3 cle_pcompl — ❌ Non pas_garde_n1 reste vide
        - 4 cle_comp_ss_num — ❌ Non pas_garde_n1 reste vide
        - 5 cle_pcompl2 — ❌ Non pas_garde_n1 reste vide
        - 6 cle_pcompl2_ss_num — ✅ OUI pas_garde_n1 = 1
    - pas_garde_n1 = 1 : FLAG → cette fiche N correspond à une fiche rejetée N-1
  - 5.3 — Rapprochement avec "fermées"
    - Même logique que "pas gardées", mais avec un flag différent : ferme_n1 = 1
      - Différence clé : interprétation du flag
        - pas_garde_n1 = 1 — Fiche invalide (doublon, erreur...) — ❌ REJETÉE automatiquement
        - ferme_n1 = 1 — Établissement fermé en N-1 — ⚠️ ALERTE : à vérifier si réouverture
      - Pourquoi différencier ?
        - Imaginons une fiche flaggée ferme_n1=1 qui réapparaît dans TripAdvisor N :
          - TripAdvisor = données récentes (scraping régulier)
          - Présence sur TA = probable réouverture ou erreur N-1
          - Résumé — Présence sur TA = probable réouverture ou erreur N-1
        - Alors qu'une fiche pas_garde_n1=1 réapparaissant dans TA :
          - Probable pollution de la base TA — → Rejet automatique sans vérification

6. Rapprochement avec N-1 "validées"

7. Séparation par source

8. Rapprochement inverse (N-1 → N)

9. Création des codens (identifiants de regroupement)

10. Attribution couleur de confiance

11. Rapprochement avec SIRENE fermés

12. Contrôles avancés (5 programmes annexes)

13. Export

Presented with xmind