OGR_RESTO : 6. Rapprochement avec N-1 "validées"

Cette étape récupère le codens_n1 (identifiant unique d'établissement) des fiches validées lors de la campagne précédente. C'est l'étape la plus stratégique car elle permet de maintenir l'historique d'un restaurant à travers les campagnes successives.

- 6.1 — Contexte et objectif
  - Situation :
    - La campagne N-1 (2022-08) a validé ~10 000 restaurants pour le département 75
    - Chaque restaurant validé a reçu un codens (code d'établissement unique)
      - 75_COMPLETE_00042
      - 75_PCOMPL_00381
    - Ces fiches sont stockées dans SASDON_1.PDVRESTO_2022_08_75 (PDV = Point De Vente)
  - Problème :
    - Les nouvelles extractions N (2025-01) contiennent des fiches nouvelles ET des fiches déjà connues
    - Pour les fiches déjà connues, on veut réutiliser le codens N-1 pour :
      - ✅ Maintenir la continuité (même ID = même restaurant dans le temps)
      - ✅ Enrichir les données (fusion infos N-1 + infos N)
      - ✅ Simplifier la validation (si match parfait → validation automatique)
  - Solution :
    - Rapprocher les extractions N avec PDVRESTO_N-1 pour récupérer le codens_n1.
- 6.2 — Différence majeure avec les étapes précédentes
  - Étapes 5 (pas gardées/fermées) :
    - But : détecter les fiches à rejeter ou surveiller
    - Méthode : 6 clés en cascade (tolérance large)
    - Résultat : flag pas_garde_n1=1 ou ferme_n1=1
  - Étape 6 (validées) :
    - But : récupérer l'identifiant permanent (codens_n1)
    - Méthode : SEULEMENT 2 clés (très strictes : cle_complete et cle_complete2)
      - cle_complete
      - cle_complete2
    - Résultat : champ codens_n1 rempli
  - Pourquoi seulement 2 clés ?
    - 🔒 Sécurité : on ne veut récupérer le codens_n1 QUE si on est quasi-certain que c'est le même restaurant.
    - Risque avec des clés larges :
      - Exemple avec cle_pcompl2_ss_num (sans n° de voie):
        - N-1 : "PIZZERIA NAPOLI", "PLACE VICTOR HUGO", "75016 PARIS"
          - → codens_n1 = "75_PCOMPL2_00
        - N : "SUSHI KING", "PLACE VICTOR HUGO", "75016 PARIS"
          - → Match sur cle_pcompl2_ss_num (adresse sans n°) !
            - → codens_n1 = "75_PCOMPL2_00123"
              - RÉCUPÉRÉ À TORT
        - Résultat : on attribue le codens de la pizzeria au resto de sushi → ERREUR GRAVE
  - Avec seulement 2 clés strictes :
    - cle_complete : dénomination + adresse complète identique
      - → match parfait
    - cle_complete2 : dénomination + adresse avec dernier mot voie
      - → tolérance minimale (ex: "RUE DE LA RÉPUBLIQUE" vs "RUE RÉPUBLIQUE")
    - → Risque de faux positif quasi nul
- 6.3 — Création des clés N-1
  - Charge la table N-1 validée :
  - Recalcule les clés (pour compatibilité) :
    - cle_complete = compress(denomination_f||numvoie||typevoie||nomvoie||compvoie||codpost||villenorm);
    - cle_complete2 = compress(denomination_f||numvoie||typevoie||last_mot_voie||compvoie||codpost||villenorm);
- 6.4 — Première passe : rapprochement sur cle_complete
  - 1. Tri de resto_4 :
    - resto_4 = table N après rapprochement pas gardées/fermées
    - Tri par cle_complete pour la fusion
  - 2. Tri et dédoublonnage de pdv_N1
  - 3. Fusion (MERGE) :
    - la ligne existe dans resto_4 (extraction N)
    - une ligne avec cette cle_complete existe dans pdv_N1
    - Résumé
      - Pas de condition if a and b → LEFT JOIN (on garde toutes les lignes de resto_4)
        - Si match (a=1 et b=1)
          - codens_n1 est rempli
        - Si pas de match (a=1 et b=0)
          - codens_n1 reste vide
- 6.5 — Deuxième passe : rapprochement sur cle_complete2
  - Même logique, mais :
    - Tri par cle_complete2
    - Le codens est renommé codens_n1_2 (pour différencier du codens_n1 de la passe 1)
- 6.6 — Fusion des deux codens
  - Si codens_n1 est rempli (match passe 1) :
    - → On garde codens_n1 (plus précis)
  - Si codens_n1 est vide mais codens_n1_2 rempli (match passe 2 uniquement) :
    - → codens_n1 = codens_n1_2 (on récupère le codens de la passe 2)
  - Si les deux sont vides :
    - → codens_n1 reste vide (nouvelle fiche, jamais vue en N-1)
  - Suppression de codens_n1_2 :
    - on supprime cette variable temporaire
    - On garde seulement codens_n1 qui contient le meilleur codens disponible
- 6.7 — Exemple concret complet
  - Scénario 1 : Match parfait (cle_complete)
    - N-1 (2022-08) :
      - Fiche validée :
        - denomination_f = "LEBISTROT"
        - numvoie = "12"
        - typevoie = "RUE"
        - nomvoie = "REPUBLIQUE"
        - compvoie = "BATA"
        - codpost = "75011"
        - villenorm = "PARIS"
        - Résumé
          - cle_complete = "LEBISTROT12RUEREPUBLIQUEBATA75011PARIS"
          - codens = "75_COMPLETE_00042"
    - N (2025-01) :
      - Extraction PJ :
        - denomination_f = "LEBISTROT"
        - numvoie = "12"
        - typevoie = "RUE"
        - nomvoie = "REPUBLIQUE"
        - compvoie = "BATA"
        - codpost = "75011"
        - villenorm = "PARIS"
        - + cle_complete = "LEBISTROT12RUEREPUBLIQUEBATA75011PARIS"
    - Conséquence :
      - Cette fiche N sera liée à la fiche N-1
      - Les informations N-1 pourront être enrichies avec les infos N
      - Si aucune info N a changé → validation automatique (couleur = 1)
  - Scénario 2 : Match sur cle_complete2 uniquement
    - N-1 (2022-08) :
      - Fiche validée :
        - denomination_f = "RESTAURANTCHEZMARIE"
        - numvoie = "8"
        - typevoie = "RUE"
        - nomvoie = "GENERALDEGAULLE" ← Nom complet
        - compvoie = ""
        - codpost = "75016"
        - villenorm = "PARIS"
        - last_mot_voie = "GAULLE"
        - Résumé
          - → cle_complete = "RESTAURANTCHEZMARIE8RUEGENERALDEGAULLE75016PARIS"
          - → cle_complete2 = "RESTAURANTCHEZMARIE8RUEGAULLE75016PARIS"
          - codens = "75_COMPLETE2_00567"
    - N (2025-01) :
      - Extraction TA :
        - denomination_f = "RESTAURANTCHEZMARIE"
        - numvoie = "8"
        - typevoie = "RUE"
        - nomvoie = "DEGAULLE" ← Version abrégée (préposition "DE" conservée car exception)
        - compvoie = ""
        - codpost = "75016"
        - villenorm = "PARIS"
        - last_mot_voie = "GAULLE"
        - Résumé
          - → cle_complete = "RESTAURANTCHEZMARIE8RUEDEGAULLE75016PARIS" ← Différent
          - → cle_complete2 = "RESTAURANTCHEZMARIE8RUEGAULLE75016PARIS" ← IDENTIQUE
    - Rapprochement
      - codens_n1 reste vide
      - cle_complete2
        - ✅ Match (dernier mot = GAULLE)
      - codens_n1_2 = "75_COMPLETE2_00567"
      - Fusion :
        - → codens_n1 = "75_COMPLETE2_00567"
      - Fiche N liée à N-1 malgré variation du nom de voie
  - Scénario 3 : Pas de match (nouvelle fiche)
    - N-1 (2022-08) :
      - Aucune fiche correspondante
    - N (2025-01) :
      - Extraction PJ :
        - denomination_f = "NOUVEAUBISTROT"
        - numvoie = "25"
        - typevoie = "RUE"
        - nomvoie = "LAFAYETTE"
        - codpost = "75010"
        - villenorm = "PARIS"
        - → cle_complete = "NOUVEAUBISTROT25RUELAFAYETTE75010PARIS"
        - → cle_complete2 = "NOUVEAUBISTROT25RUELAFAYETTE75010PARIS"
        - Rapprochement :
          - cle_complete
            - ❌ Aucune fiche N-1 avec cette clé
              - codens_n1 reste vide
          - cle_complete2
            - ❌ Aucune fiche N-1 avec cette clé
              - codens_n1_2 reste vide
          - Résultat :
            - codens_n1 = "" (vide)
            - Nouvelle fiche, jamais validée auparavant
            - Nécessite validation manuelle complète
            - Recevra un nouveau codens lors de l'étape 9 (création des codens)
- 6.8 — Importance stratégique du codens_n1
  - 1. Continuité historique
    - Résultat : on peut suivre l'évolution d'un même restaurant sur 8 ans avec le même identifiant.
  - 2. Enrichissement progressif
    - Base de données finale = cumul des informations de toutes les campagnes
  - 3. Validation accélérée

Presented with xmind