OGR_RESTO : 8. Rapprochement inverse (N-1 → N)

Cette étape inverse la logique des étapes précédentes. Au lieu de partir des extractions N pour chercher dans N-1, on part de la base validée N-1 et on cherche quelles nouvelles extractions N correspondent à chaque restaurant déjà connu.

- 8.1 — Contexte et objectif
  - Différence fondamentale avec les étapes précédentes :
    - Étapes 5-6
      - Direction : N → N-1
      - Point de départ : Extractions N
      - Question : "Cette fiche N existait-elle en N-1 ?"
      - Résultat : Flag sur les fiches N (codens_n1, pas_garde_n1)
      - Utilité : Récupérer l'historique
    - Étape 8
      - Direction : N-1 → N
      - Point de départ : Base validée N-1
      - Question : "Cette fiche N-1 existe-t-elle encore dans les sources N ?"
      - Résultat : Flag sur les fiches N-1 (PJ_N, TA_N, STOCK_N, FERM_N)
      - Utilité : Détecter disparitions/confirmations
- 8.2 — Préparation de la base N-1
  - Chargement de la base N-1 complète
  - Nettoyage de l'adresse
    - Pourquoi nettoyer N-1
      - La base N-1 a peut-être été créée avec d'anciennes règles de nettoyage
      - On applique les mêmes transformations que sur les extractions N (étape 2)
      - Garantit la compatibilité entre N-1 et N pour le rapprochement
  - Renommage du codens
    - Pourquoi ?
      - La table N-1 a un champ codens (identifiant permanent)
      - On le renomme codens_n1 pour éviter confusion avec le futur codens qui sera calculé à la fin
      - codens_n1 = identifiant de la campagne N-1
  - Flag extraction
    - extrac = numéro d'extraction/campagne
    - 5 = code pour "fiche issue de N-1" (convention du projet)
    - Permet de différencier les fiches N-1 des fiches N dans la fusion finale
  - Suppression colonnes temporaires :
    - id_pj_1, id_pj_2, id_ta_1, etc. = identifiants des sources N-2, N-3... (historique)
    - date_data = date de l'extraction N-1 (obsolète)
    - date_inser = date d'insertion N-1 (obsolète)
    - Résumé → On nettoie pour ne garder que l'essentiel
  - Passe 1
    - Logique :
      - cle_complete
      - cle_complete2
      - cle_comp_ss_num
      - cle_pcompl2_ss_num
      - → les extrac PJ N non rapprochées
      - Cas : Match → Condition : a=1 et b=1 → Action : PJ_N=1 + output BDD_RESTO_N1 → Résultat : Fiche N-1 existe dans PJ N
      - Cas : N-1 seule → Condition : a=1 et b=0 → Action : output BDD_RESTO_N1 → Résultat : Fiche N-1 pas dans PJ (pas grave)
      - Cas : PJ seule → Condition : a=0 et b=1 → Action : output pj_reste → Résultat : Nouvelle fiche PJ (pas en N-1)
    - Exemple concret :
      - BDD_RESTO_N1 ligne 42 : "LEBISTROT", "12 RUE REPUBLIQUE", "75011 PARIS" → cle_complete = "LEBISTROT12RUEREPUBLIQUE75011PARIS" → PJ_N = . (vide au départ)
      - pj (source PJ 2025) : Ligne 101 : "LE BISTROT", "12 RUE REPUBLIQUE", "75011 PARIS" → cle_complete = "LEBISTROT12RUEREPUBLIQUE75011PARIS"
      - Après fusion :
        - BDD_RESTO_N1 ligne 42 : → PJ_N = 1 ✅ (restaurant confirmé dans PJ N)
        - pj ligne 101 : → Retirée de pj, ne va PAS dans pj_reste (car matchée)
        - Si PJ ligne 101 n'avait PAS matché :
          - BDD_RESTO_N1 ligne 42 : → PJ_N reste vide (pas confirmé par PJ)
          - pj ligne 101 : → Va dans pj_reste (nouvelle fiche à traiter)
  - Passes 2-4
    - Filtre préliminaire → Ne traite QUE les fiches PJ non matchées à la passe 1 (pj_reste)
    - Nouvelle clé : cle_complete2 (au lieu de cle_complete)
    - Exemple concret :
      - BDD_RESTO_N1 ligne 42 : "RESTAURANTGAULLE", "8 RUE GENERAL DE GAULLE", "75016"
        - → cle_complete = "RESTAURANTGAULLE8RUEGENERALDEGAULLE75016PARIS"
        - → cle_complete2 = "RESTAURANTGAULLE8RUEGAULLE75016PARIS" (dernier mot)
        - → PJ_N = . (pas de match passe 1)
      - pj_reste (fiches PJ non matchées passe 1) : "RESTAURANT GAULLE", "8 RUE DE GAULLE", "75016"
        - → cle_complete = "RESTAURANTGAULLE8RUEDEGAULLE75016PARIS" ← Différent !
        - → cle_complete2 = "RESTAURANTGAULLE8RUEGAULLE75016PARIS" ← IDENTIQUE !
      - Résumé → BDD_RESTO_N1 ligne 42 : → PJ_N = 1 ✅ (match sur cle_complete2)
  - Passe 3
    - Usage : détecte les fiches sans numéro de voie
    - Exemple :
      - N-1 : "PIZZERIA NAPOLI", "5 PLACE VICTOR HUGO", "75016" → cle_comp_ss_num = "PIZZERIANAPOLI PLACEVICTORHUGO75016PARIS"
      - PJ N : "PIZZERIA NAPOLI", "PLACE VICTOR HUGO", "75016" (sans n°) → cle_comp_ss_num = "PIZZERIANAPOLI PLACEVICTORHUGO75016PARIS"
      - → Match passe 3 !
  - Passe 4
    - Usage : la plus large (sans n° ni complément, avec dernier mot voie)
    - Exemple :
      - N-1 : "BISTROT PARIS", "12 RUE DE LA REPUBLIQUE BAT A", "75011" → cle_pcompl2_ss_num = "BISTROTPARISRUEREPUBLIQUE75011PARIS"
      - PJ N : "BISTROT PARIS", "RUE REPUBLIQUE", "75011" (sans n° ni complément) → cle_pcompl2_ss_num = "BISTROTPARISRUEREPUBLIQUE75011PARIS"
      - → Match passe 4 !
  - Création de pj_reste_fin
    - fiches PJ non matchées après les 4 passes
    - On récupère les fiches complètes de pj (avec toutes les colonnes) dont la cle_pcompl2_ss_num est dans pj_reste_4
    - Résultat → pj_reste_fin = nouvelles fiches PJ (jamais vues en N-1)
- 8.3 — Rapprochement avec PJ (4 passes)
- 8.4 — Rapprochement avec TA → (identique à PJ)
- 8.5 — Rapprochement avec STOCK → (code manuel, même logique)
- 8.6 — Rapprochement avec FERM
  - Passe 0 spéciale : rapprochement sur SIREN !
    - Pourquoi commencer par le SIREN ?
      - SIREN = identifiant unique officiel de l'entreprise
      - Si un restaurant N-1 a le même SIREN qu'un établissement fermé dans SIRENE → fermeture avérée (très fiable) → C'est un match fort, même si l'adresse ou le nom ont changé
    - Exemple :
      - BDD_RESTO_N1 ligne 42 : "LE BISTROT", "12 RUE REPUBLIQUE", "75011 PARIS" / siren = "123456789" / FERM_N = . (vide au départ)
      - FERM (SIRENE fermés 2025) : "BISTROT PARISIEN", "10 RUE REPUBLIQUE", "75011 PARIS" (adresse changée !) / siren = "123456789" ← MÊME SIREN / datederniertraitementetablisseme = "2024-06-15" (fermé en juin 2024)
      - Après passe 0 sur SIREN : BDD_RESTO_N1 ligne 42 : → FERM_N = 1 ⚠️ (établissement fermé dans SIRENE) / Conséquence : Vérifier si établissement encore ouvert (présent dans SIRENE fermés)
  - Passes 1-5 → Même pattern que STOCK, sauf qu'on ne traite que les SIREN non matchés à la passe 0.
  - Colonnes ajoutées :
    - PJ_N → Restaurant présent dans PJ N → 1 ou vide
    - TA_N → Restaurant présent dans TA N → 1 ou vide
    - STOCK_N → Restaurant présent dans STOCK N (SIRENE actifs) → 1 ou vide
    - FERM_N → Restaurant présent dans FERM N (SIRENE fermés) → 1 ou vide
  - Exemples de combinaisons :
    - Ex 1 : PJ_N :1 / TA_N :1 / STOCK_N : 1 / FERM_N : → ✅ Confirmé partout (restaurant actif, bien visible)
    - Ex 2 : PJ_N :1 / TA_N :1 / STOCK_N : / FERM_N : → ✅ Confirmé PJ+TA (actif mais pas dans SIRENE ou SIREN manquant)
    - Ex 3 : PJ_N : / TA_N : / STOCK_N : 1 / FERM_N : → ⚠️ STOCK seul (actif SIRENE mais peu visible en ligne)
    - Ex 4 : PJ_N : / TA_N : / STOCK_N : / FERM_N : 1 → ⚠️ FERM seul (fermé dans SIRENE, pas d'autre source) → Probable fermeture
    - Ex 5 : PJ_N : 1 / TA_N : 1 / STOCK_N : / FERM_N : 1 → ⚠️ PJ+TA mais FERM (sources contradictoires) → Vérification manuelle requise
- 8.7 — État de BDD_RESTO_N1 après tous les rapprochements
- 8.8 — Tables de "restes" (nouvelles fiches)
  - Après tous les rapprochements, on a 4 tables de nouvelles fiches :
    - pj_reste_fin → Nouvelles fiches PJ (pas en N-1)
    - ta_reste_fin → Nouvelles fiches TA (pas en N-1)
    - stock_reste_fin → Nouveaux STOCK (pas en N-1)
    - ferm_reste_fin → Nouveaux FERM (pas en N-1)
- 8.9 — Pourquoi ce rapprochement inverse est crucial ?
  1. Détection des disparitions
  2. Hiérarchisation des fiches
     - Ordre de priorité (code à l'étape suivante) :
       - Fiches N-1 confirmées par plusieurs sources → couleur_fin = 1 (validation auto)
       - Fiches N-1 confirmées par une source → couleur_fin = 2 (OK rapide)
       - Fiches N-1 non confirmées + nouvelles fiches N → couleur_fin = 3-4 (validation manuelle)
  3. Enrichissement progressif
  4. Détection des incohérences

Presented with xmind