# OGR_RESTO : 9. Création des codens (identifiants de regroupement)

**Cette étape crée les codens (codes d'établissement) qui vont regrouper toutes les fiches désignant le même restaurant. C'est l'étape la plus algorithmiquement complexe car elle doit détecter les doublons à travers des variations d'écriture, de sources, et de complétion des données.**

- 9.1 — Contexte et objectif
  - Situation après l'étape 8 :
    - BDD_RESTO_N1
      - (10 000 fiches N-1 avec flags PJ_N, TA_N, STOCK_N, FERM_N)
    - pj_reste_fin (800 nouvelles fiches PJ)
    - ta_reste_fin (600 nouvelles fiches TA)
    - stock_reste_fin (3 000 nouvelles fiches STOCK)
  - Problème : certaines de ces fiches désignent le même restaurant :
    - Exemple :
      - Ligne 42 (N-1) : "LE BISTROT", "12 RUE REPUBLIQUE", "75011 PARIS", source=N-1
      - Ligne 3045 (PJ) : "LE BISTROT", "12 RUE REPUBLIQUE BAT A", "75011 PARIS", source=PJ
      - Ligne 7821 (TA) : "BISTROT", "12 RUE DE LA REPUBLIQUE", "75011", source=TA
      - Ligne 9234 (STOCK) : "LE BISTROT PARISIEN", "12 R REPUBLIQUE", "75011", source=STOCK
      - 4 fiches différentes = 1 seul restaurant physique
  - Objectif :
    - Attribuer un codens unique à ces 4 fiches pour signaler qu'elles doivent être agrégées en une seule entrée finale dans la base de données.
- 9.2 — Filtrage des fiches "pas gardées" et "fermées N-1"
  - Il trie les nouvelles fiches (xx_reste_fin) en 3 catégories :
    - pas_garde_n1=1 → Sauvegardées dans PAS_GARDES_N1_2025_01_75
      - Ces fiches avaient déjà été rejetées en N-1
      - On les met de côté, elles ne participeront PAS à la création des codens
      - Elles seront rejetées automatiquement sans validation
    - ferme_n1=1 → Sauvegardées dans FERMES_N1_2025_01_75
      - Ces fiches correspondaient à des établissements fermés en N-1
      - On les met de côté, elles ne participeront PAS à la création des codens
      - Elles seront vérifiées manuellement (possible réouverture)
    - Autres → Réécrites dans PJ_RESTE_FIN, TA_RESTE_FIN, STOCK_RESTE_FIN
      - Fiches "propres" (ni rejetées ni fermées en N-1)
      - Ces fiches participeront à la création des codens
- 9.3 — Création de la liste de clés (Liste_cle)
  - Il crée une table de référence contenant toutes les clés distinctes de :
    - Nouvelles fiches PJ (propres)
    - Nouvelles fiches TA (propres)
    - Nouvelles fiches STOCK (propres)
    - Toutes les fiches N-1 (BDD_RESTO_N1)
      - Pourquoi inclure N-1 ?
        - Les fiches N-1 ont déjà un codens (codens_n1), mais on doit quand même les inclure car :
          - Certaines fiches N-1 pourraient être liées entre elles via de nouvelles clés
          - Les nouvelles fiches N doivent pouvoir se rattacher aux codens N-1 existants
- 9.4 — Calcul des codens par clé (9 passes)
  - Étape 1 : Identifier les doublons sur cle_complete2
    - Exemple résultat :
      - cle_complete2
        - LEBISTROT12RUEREPUBLIQUE75011PARIS
          - nb : 3
        - PIZZERIANAPOLI8PLACEVICTORHUGO75016PARIS
          - nb : 2
  - Étape 2 : Créer un codens pour chaque groupe
    - Exemple résultat :
      - cle_complete2
        - LEBISTROT12RUEREPUBLIQUE75011PARIS
          - nb : 3
            - codens_1 : 75_COMPLETE2_00001
        - PIZZERIANAPOLI8PLACEVICTORHUGO75016PARIS
          - nb : 2
            - codens_1 : 75_COMPLETE2_00002
      - Structure du codens :
        - 75 = département
        - COMPLETE2 = nom de la clé utilisée (pour traçabilité)
        - 00001 = numéro séquentiel (unique)
  - Étape 3 : Fusionner avec Liste_cle
    - Résultat dans Liste_cle :
      - cle_complete cle_complete2 codens_1
      - LEBISTROT12RUEREPUBLIQUE75011PARIS LEBISTROT12RUEREPUBLIQUE75011PARIS 75_COMPLETE2_00001
      - LEBISTROT12RUEREPUBLIQUEBATA75011PARIS LEBISTROT12RUEREPUBLIQUE75011PARIS 75_COMPLETE2_00001
      - LEBISTROT12RUEREPUBLIQUE75011PARIS LEBISTROT12RUEREPUBLIQUE75011PARIS 75_COMPLETE2_00001
      - PIZZERIANAPOLI8PLACEVICTORHUGO75016 PIZZERIANAPOLI8PLACEVICTORHUGO75016 75_COMPLETE2_00002
      - PIZZERIANAPOLI8PLACEVHUGOBATA75016 PIZZERIANAPOLI8PLACEVICTORHUGO75016 75_COMPLETE2_00002
      - NOUVEAUSUSHI20RUEMONTMARTRE75001 NOUVEAUSUSHI20RUEMONTMARTRE75001 . (vide, pas de doublon)
      - Observation :
        - Les 3 premières lignes ont le même codens_1 car elles partagent cle_complete2
        - "NOUVEAUSUSHI." n'a pas de doublon → codens_1 reste vide
  - Passes 2-9 : même logique, clés différentes
    - Après les 9 passes, Liste_cle contient :
      - cle_complete cle_complete2 … codens_1 codens_2 … codens_9
      - Une ligne peut avoir plusieurs codens si elle correspond à des groupes différents selon les clés.
- 9.5 — Dédoublonnage par score (encore)
  - Pourquoi re-dédoublonner ?
    - Dans N-1 (doublons hérités de campagnes précédentes)
    - Créés lors des fusions multiples
  - Logique : pour chaque cle_complete identique, ne garde que la ligne avec le score maximal (nombre de champs remplis).
- 9.6 — Fusionner les codens avec les données
  - Concaténation verticale de toutes les fiches :
  - Résultat :
    - Chaque table source (pj_reste_fin, ta_reste_fin, etc.) reçoit les 9 codens calculés via la jointure sur cle_complete.
- 9.7 — Fusion de toutes les sources
  - Concaténation verticale de toutes les fiches :
    - Total : ~ **** lignes avec jusqu'à 10 codens par ligne (codens_n1 + 9 nouveaux).
- 9.8 — Sélection du codens final
  - Logique de priorité :
    - Priorité : codens_1 > codens_2 > … > codens_9
- 9.9 — Attribution du code couleur de validation
  - Il extrait le nom de la clé du codens et attribue une couleur de validation (niveau de confiance).
- 9.10 — Vidage des codens uniques
  - Logique :
    - Si un codens n'apparaît qu'une seule fois, on le vide.
  - Pourquoi ?
    - Un codens sert à regrouper plusieurs fiches. S'il n'y a qu'une fiche, le codens est inutile.
- 9.11 — Rapprochement des fiches sans codens avec les fiches groupées
  - Situation :
    - Après %videcodens, certaines fiches ont codens="" (vide) :
      - Soit elles n'ont jamais eu de doublon
      - Soit leur codens était unique et a été vidé
  - Objectif :
    - Essayer de rattacher ces fiches orphelines aux codens existants via 6 clés.

Presented with xmind