BD-Resto: Un pipeline de normalisation et validation d'adresses postales

Dérnière mise à jour: 09-04-2026

- **1- Traitement Adresse**
  - Étape 0 — Consolidation des sources
0- Préparation de la table contenant toutes les adresses des OGR.sas
    - rassemble les adresses provenant de multiples sources
      - Pages Jaunes
      - TripadVisor
  - Étape 1 — Traitement automatique (« Appelé 1 »)
Appelé 1-Traitement adresse.sas
    - orchestre ~21 macros enchaînées qui découpent une adresse brute (champ texte unique)
      - Program sas : MacroAdr1
        - Nettoyage des caractères spéciaux et accents
          - Les accents sont retirés (é→e, ç→c, ô→o, etc.)
          - Tous les symboles deviennent des espaces : -, ., „ /, (,), @, :, ', ", etc.
          - Mise en MAJUSCULES
          - Suppression des espaces multiples
          - AVANT : "12, Bd Victor-Hugo — 75016 PARIS Cédex"
APRÈS : "12 BD VICTOR HUGO 75016 PARIS CEDEX"
      - Program sas : MacroAdr2
        - Extraction du code postal et de la ville
          - AVANT : "12 BD VICTOR HUGO 75016 PARIS"
APRÈS : adresse="12 BD VICTOR HUGO" | codpost="75016" | ville="PARIS"
      - Program sas : MacroAdr3
        - Normalisation des expressions courantes
          - La plus grosse étape. Elle standardise des centaines d'abréviations et de variantes
            - Abréviations courantes — RESID→RESIDENCE, FBG→FAUBOURG, BAT→BATIMENT, LOT→LOTISSEMENT, LD→LIEU DIT
            - Case postale — C P, C.P. → CP
            - Zones industrielles — Z I, Z.A.C, Z A E → ZI, ZAC, ZAE
            - Espaces commerciaux — GAL COM → GALERIE COMMERCIALE
            - Centres commerciaux — CTRE CIAL, CC, CCIAL, C CIAL → CENTRE COMMERCIAL
            - Galeries marchandes — GAL MARCHANDE, GALE MARCH → GALERIE MARCHANDE
            - Grades militaires — GEN→GENERAL, LT→LIEUTENANT, CDT→COMMANDANT, DR→DOCTEUR
            - Présidents — PRES→PRESIDENT, PDT→PRESIDENT + corrections noms (MITERRAND→MITTERRAND)
            - Unités militaires — RI=Régiment d'Infanterie, DB=Division Blindée + ordinaux (1 ER→1ER)
            - Noms de rues célèbres — DE LATTE→DE LATTRE DE TASSIGNY, MAL FOCH→MARECHAL FOCH
            - Saints — SAINT→ST, SAINTE→STE
      - Program sas : MacroAdr4/5 — Normalisation BP (boîte postale) et CP
      - Program sas : MacroAdr6 — Normalisation du type de voie (RUE, AVENUE...)
      - Program sas : MacroAdr7 — Traitement des CEDEX
      - Program sas : MacroAdr8/9 — Extraction des zones (ZAC, ZI, centre commercial...)
      - Program sas : MacroAdr12-18 — Extraction du numéro de voie, BIS/TER, type de voie
      - Program sas : MacroAdr21 — Suppression des espaces multiples
      - Résultat
        - l'adresse brute "12 BIS RUE VICTOR HUGO 75001 PARIS"
          - est éclatée en → numvoie=12, compvoie=BIS, typevoie=RUE, nomvoie=VICTOR HUGO, codpost=75001, ville=PARIS
  - Étape 2 — Corrections manuelles connues (« Appelé 2 »)
Appelé 2- Correction séparation auto vues précedemment.sas
    - applique des corrections cas par cas — des adresses mal découpées identifiées les années précédentes
      - base de connaissances des erreurs connues
        - 1. Corrections « en dur » cas par cas
          - 5 grandes familles d'erreurs corrigées
            - Ville polluée — ville="1 R VASCO DE GAMA 44955 NANTES" — On redistribue : numvoie="1", typevoie="RUE", nomvoie="VASCO DE GAMA", codpost="44955", ville="NANTES"
            - Nom de voie trop long (contient un complément collé) — nomvoie="JEAN JAURES L ORANGERIE" — On coupe : nomvoie="JEAN JAURES", compvoie="L ORANGERIE"
            - Type de voie absorbé dans le nom — nomvoie="R AMIRAL COURBET" — On extrait : typevoie="RUE", nomvoie="AMIRAL COURBET"
            - Code postal / ville mélangés — ville="35517 CESSON SEVIGNE" — On sépare : codpost="35517", ville="CESSON SEVIGNE"
            - Fautes d'orthographe — nomvoie="CHARLES DE GAULE" — → "CHARLES DE GAULLE"
        - 2. Nettoyages semi-génériques
        - 3. Macros de vérification
          - appelle des macros de contrôle
macro1_7a à macro1_7f
            - Le numvoie ne contient-il pas de texte parasite (ex: 32RR) ?
            - Le nomvoie contient-il encore un type de voie non extrait ?
            - typevoie vide alors que numvoie rempli → incohérence ?
            - typevoie vide → cas à investiguer
            - nomvoie contient des mots comme « AGENCE », « SALLE COURRIER » → à nettoyer
  - Étape 3 — Validation manuelle
1- Traitement adresse auto et vérification des adresses - Fichiers BAN.sas
    - Phase 1 - Génère une clé unique par adresse (cle = dep + compvoie + codpost + ville + numvoie + typevoie + nomvoie)
      - cle = compress(dep||"C"||compvoie||codpost||ville||numvoie||"T"||typevoie||"N"||nomvoie||adressecompl); — → c'est l'identité unique de cette adresse découpée
      - 75CIMMEUBLE APOLLO75001PARIS12TRUEVICTOR HUGO
    - Phase 2 - Compare avec la table ValidManAdrExtracOK (corrections manuelles déjà validées)
      - Un MERGE par clé sépare les adresses en deux flux
        - Adress auto valide : ADRAutoOK
          - Clé trouvée dans l'historique
          - Adresse déjà validée une année précédente — → on réutilise la correction
        - Adress à valide manuellement : AdrManuel
          - Clé absente de l'historique
          - Adresse nouvelle — → à envoyer en validation manuelle
        - C'est le mécanisme d'apprentissage cumulatif : chaque année, le volume à valider manuellement diminue car les corrections s'accumulent.
    - Phase 3 - Sépare en ADRAutoOK (déjà validées) et AdrManuel (à valider manuellement)
      - Export pour validation humaine
        - La table AdrManuel est enrichie avec le nom de l'agence (pour aider le validateur) puis exportée en Excel
          - Le fichier contient les colonnes de l'adresse découpée automatiquement + 6 colonnes vides pour les corrections :
            - Colonnes auto (lecture seule) — numvoie, typevoie, nomvoie, compvoie, codpost, ville
            - Colonnes manuelles (à remplir) — numvoie2, typevoie2, nomvoie2, compvoie2, codpost2, ville2
    - Phase 4 - PAUSE : Validation humaine
      - Surligner en jaune les lignes où codpost ou ville sont vides
      - Pour corriger un champ — remplir la colonne *2 correspondante (ex: nomvoie2)
      - Pour vider un champ → écrire "VIDE" dans la colonne *2
      - Pour supprimer une ligne (pas une adresse) → mettre "VIDE" dans nomvoie2
      - Points de vigilance
        - 1 - Vérifier que numvoie ne contient pas de texte parasite
        - 2 - Le codpost doit faire exactement 5 chiffres
        - 3 - La ville doit être remplie pour tout le monde
        - 4 - Si nomvoie contient encore un complément collé → le séparer dans compvoie2
        - 5 - Attention aux numéros de voie très grands (souvent suspects)
      - Le fichier validé est sauvegardé sous — ValidManAdrExtractionOK.xlsx.
    - Phase 5 - Réimport et fusion
      - Import du fichier Excel validé
      - Re-merge avec toutes les adresses pour appliquer les corrections
      - Application des corrections : — si *2 contient une valeur → elle remplace le champ original ; si *2 = "VIDE" → le champ est vidé ; si nomvoie2 = "VIDE" → la ligne est supprimée
      - Nettoyage final : suppression des adresses sans nom de voie, des adresses en Andorre, recalcul du département
  - INPUT (champ texte brut unique)
    - "12 BIS R VICTOR HUGO CTR COM LECLERC 75001 PARIS"
      - MacroAdr2 : extrait codpost, ville
      - MacroAdr6 : R → RUE
      - MacroAdr8/9: isole CENTRE COMMERCIAL
      - MacroAdr12: crée numvoie/nomvoie
      - MacroAdr17: isole BIS/TER
      - MacroAdr18: extrait typevoie
        - OUTPUT (champs structurés séparés)
          - numvoie — 12
          - typevoie — RUE
          - nomvoie — VICTOR HUGO
          - compvoie — CENTRE COMMERCIAL LECLERC
          - codpost — 75001
          - ville — PARIS
- **2- Géocodage commune**
  - Phase 1 — Normalisation de la ville (villenorm)
    - Transformer le champ ville (saisi/extrait, avec erreurs) en un champ villenorm correspondant à un nom de commune officiel.
      - Étape 1.1 — Préparation
        - Création du champ NOM (nom de l'établissement) pour aider aux rapprochements
        - Nettoyage du champ ville via %macroAdr1 (suppression accents, symboles)
        - Suppression de cas étrangers (Luxembourg, Suisse, Allemagne, Andorre)
        - Suppression des adresses vides ou avec dep="98" (Monaco, étranger)
      - Étape 1.2 — Rapprochement automatique en 3 passes
        - codpost + villevalid (ville avec ST/STE) — Table de référence : geo.listevillenorm — → ficvilleok (OK) ou passe 2
        - typevoie + nomvoie + compvoie + codpost + ville — Table de référence geo.corvilleparadr — → ficvilleok2 (OK) ou passe 3
        - NOM + typevoie + nomvoie + compvoie + codpost + ville — Table de référence : geo.corvilleparCLECOMPLETE — → ficvilleok3 (OK) ou validation manuelle
      - Étape 1.3 — Validation manuelle de la ville
        - Recherche la bonne villenorm en s'aidant du compvoie, du nom, de Google Maps
        - Attribue un TYPERAP (type de rapprochement)
          - 1 = ville trouvée via l'adresse seule (cas général : erreur CP ou coquille)
          - 2 = ville trouvée uniquement grâce au nom complet de l'établissement
          - 4 = forçage (fusions de communes, quartiers devenus communes)
            - Après import : Les corrections alimentent geo.corvilleparadr — Ce tables grossisse chaque année, réduisant le volume de validation manuelle
          - 3 = ville trouvée via Street View, quasi certaine
            - Après import : Les corrections alimentent geo.corvilleparCLECOMPLETE — Ce tables grossisse chaque année, réduisant le volume de validation manuelle
          - ETR = établissement à l'étranger → supprimé
      - Étape 1.4 — Boucle de contrôle
        - Le sous-programme est relancé : la table validmanuelleville4 doit être vide (0 enregistrements). Si non vide, il faut corriger et recommencer.
          - Sortie : &ficinit.OK — table avec un champ villenorm validé pour chaque enregistrement.
      - Le problème de départ
        - Le champ ville issu de l'étape 1 est brut et hétérogène
          - on peut trouver
            - "ST NAZAIRE" ← abréviation
            - "SAINT-NAZAIRE" ← tiret
            - "SAINT NAZAIRE CDX" ← CEDEX parasite
            - "NAZAIRE" ← article oublié
            - "SAINT NAZ" ← coquille
              - Resultat — SAINT NAZAIRE
  - Phase 2 — Correction des codes postaux
    - But : S'assurer que la combinaison codpost + villenorm existe dans le référentiel postal officiel.
      - Étape 2.1 — Rapprochement automatique en 3 passes
        - codpost + villenorm — Table de référence : geo.listevillenorm — → CPok (OK) ou passe 2
        - Rapprochement par nom de voie — Table de référence : geo.Hexavia_voieexport (base La Poste) — CPok2 (OK) ou passe 3
        - Rapprochement via geo.TablecorCPn_1 (corrections manuelles accumulées) — → CPok3 (OK) ou CPfaux3 (à corriger)
      - Étape 2.2 — Correction automatique des cas simples
        - Pour les villes ayant un seul code postal dans geo.listevillenorm, le bon CP est attribué automatiquement.
      - Étape 2.3 — Validation manuelle des CP
        - CPfaux3 est exporté en Excel (Validation_CP.xlsx)
          - validateur
            - Remplit codpostH (code postal Hexavia corrigé) en cherchant sur Google Maps
            - Peut aussi corriger villenorm si l'adresse correspond en fait à une autre ville
              - Après import : Les corrections alimentent geo.TablecorCPn_1
      - Étape 2.4 — Contrôle final des CP
        - Un test vérifie que toute combinaison codpost + villenorm existe dans geo.listevillenorm. Si des cas subsistent (pbListevillenorm2)
          - export/import/correction jusqu'à résolution.
            - Sortie : &ficinit avec codpost et villenorm validés et cohérents.
      - Le problème fondamentals
        - À l'issue de la Phase 1, chaque enregistrement a un villenorm (nom de commune normalisé), mais le codpost vient toujours du texte brut extrait en Étape 1.
Or le codpost sera indispensable en Phase 3 pour retrouver le CODINSEE — une erreur ici propage une mauvaise commune en sortie.
          - Ce code postal peut être erroné : faute de frappe dans la source
          - code postal d'un quartier voisin
          - commune multi-CP, données obsolètes
  - Phase 3 — Géocodage commune (attribution du code INSEE)
    - But : Attribuer le codinsee (code commune INSEE) et le nom commune officiel à chaque enregistrement.
      - Étape 3.0 — Préparation
        - Suppression des territoires hors France (Saint-Barthélemy, Saint-Martin, Nouvelle-Calédonie, etc.) — → Table de référence : table _HFR
        - Corrections manuelles spécifiques (Orly, Paray-Vieille-Poste, etc.)
      - Étape 3.1 — Séparation Paris / Lyon-Marseille / Reste
        - Paris (20 arrondissements)
        - Lyon (9) et Marseille (16)
          - Ils ont un seul code postal pour plusieurs communes INSEE (arrondissements). Le géocodage nécessite un traitement spécial par rue.
        - Reste (tous les autres)
      - Étape 3.2 — Géocodage du « Reste »
        - 4 passes de rapprochement successives contre la table CPIM (référentiel INSEE)
          - codpost + clevil (ville normalisée nettoyée) — Match direct CP+commune
          - dep + clevil — Match par département (pour les CP erronés résiduels)
          - Via CorrespVillenorm_Com.xlsx — Table de correspondance manuelle villenorm → commune
          - Match élargi dep + clevil avec les correspondances — Dernière tentative
          - Les cas non résolus — → ValidGeomanuelle — → pause validation manuelle.
      - Étape 3.3 — Géocodage de Paris / Lyon / Marseille (Partie 2)
        - Pour ces 3 villes, le codinsee (arrondissement) est déterminé par le code postal :
          - Paris — CP 75001→75020 → codinsee 75101→75120
          - Lyon — CP 69001→69009 → codinsee 69381→69389
          - Marseille — CP 13001→13016 → codinsee 13201→13216
        - Vérification que tous les codinsee attribués sont valides (pas de 75000, pas de 69000, etc.).
      - Étape 3.4 — Assemblage final (Partie 3)
        - Fusion des 3 flux (Reste + Paris + Lyon/Marseille) → &ficout
        - Recalcul du département depuis codinsee
        - Suppression des variables de travail
        - Vérification : PB_FIN (codinsee vide) doit être vide
        - Contrôle : nobsinit = nobsfin (aucun enregistrement perdu)
      - Sortie finale → &ficin.G (ex: RESTO_2025_01_75ADROKG) : table géocodée au niveau commune, prête pour l'étape 3 (géocodage XY).
  - Résoudre le problème des fusions de communes et de l'instabilité géographique française pour attribuer à chaque point de vente le code commune INSEE officiel et actuel, seul identifiant géographique stable utilisable pour le géocodage XY.
    - INPUT (issu de l'étape 1)
codpost="49160" ville="LONGUE"
      - [Normalisation ville]
villevalid = codpost + "LONGUE"
→ pas dans LISTEVILLENORM
        - [macroCORvillenorm2018]
"LONGUE" + CP "49160"
→ villenorm = "LONGUE JUMELLES" ← fusion connue
          - [Rapprochement CPIM]
clé: dep="49" + clevil="LONGUEJUMELLES"
→ COMMUNE="LONGUE JUMELLES"
CODINSEE="49181" ✓
            - OUTPUT
codpost="49160" villenorm="LONGUE JUMELLES"
COMMUNE="LONGUE JUMELLES" CODINSEE="49181"

Presented with xmind