OGR_RESTO : Dédoublonnage par score

Cette étape résout un problème critique : pour une même clé de rapprochement, on peut avoir plusieurs lignes avec des niveaux de complétude différents. Il faut choisir la ligne la plus riche en informations.

- 4.1 — Le problème : doublons avec informations partielles
  - Exemple concret
    - Après l'étape 3, on peut avoir cette situation :
      - PJ
        - id — 101
        - denomination_f — LEBISTROT
        - cle_complete — LEBISTROT12RUE_PARIS
        - activite — Restaurant
        - ambiance — Convivial
        - budget — €€
        - type_cuisine — Français
        - telephone — 0145678901
        - site — bistrot.fr
      - TA
        - id — 205
        - denomination_f — LEBISTROT
        - cle_complete — LEBISTROT12RUE_PARIS
        - activite
        - ambiance — Chaleureux
        - budget
        - type_cuisine — Français, Européen
        - telephone
        - site
      - STOCK
        - id — 876
        - denomination_f — LEBISTROT
        - cle_complete — LEBISTROT12RUE_PARIS
        - activite
        - ambiance
        - budget
        - type_cuisine
        - telephone
        - site
    - Résumé
      - Les 3 lignes ont la même cle_complete → c'est le même restaurant
      - Mais elles ont des informations complémentaires différentes
    - Question : laquelle garder ?
      - laquelle garder ?
- 4.2 — La solution : calcul d'un score de complétude
  - Étape A : Calcul du score
    - La macro parcourt les champs spécifiés et compte combien sont non vides :
      - nb_remp
  - Étape B : Tri par score décroissant
  - Étape C : Suppression des doublons
    - on ne conserve que la première ligne de chaque groupe, c'est-à-dire celle avec le score le plus élevé.
- 4.3 — Pourquoi c'est crucial ?
  - Problème 1 : Redondance d'informations
    - Sans ce dédoublonnage, on aurait 3 lignes pour "Le Bistrot" qui seraient ensuite traitées séparément dans les rapprochements → multiplication par 3 du volume de données à traiter.
  - Problème 2 : Perte d'information dans les étapes suivantes
    - Les étapes ultérieures (rapprochement avec N-1, agrégation par codens) fonctionnent mieux avec une seule ligne de référence par clé.
  - Problème 3 : Qualité de validation
    - LE BISTROT - PJ - 12 RUE REPUBLIQUE - 0145678901 - bistrot.fr
    - LE BISTROT - TA - 12 RUE REPUBLIQUE - (pas de tel) - (pas de site)
    - LE BISTROT - STOCK - 12 RUE REPUBLIQUE - (pas de tel) - (pas de site)
- 4.6 — Cas particuliers et subtilités
  - Cas 1 : Égalité de score
    - Résultat : La première dans l'ordre de tri est gardée (ici, PJ car by source id initial)
    - Impact : Si PJ et TA ont des infos différentes mais même score, on perd les infos de TA → c'est une limite du système
  - Cas 2 : Champs vides vs espaces
  - Cas 3 : Qualité vs quantité
    - PJ : 10 champs remplis mais type_cuisine — = "Restaurant" (générique)
    - TA : 3 champs remplis mais type_cuisine — = "Cuisine française, bistronomique, produits locaux" (précis)
    - Problème : PJ est gardé (score 10) mais son info est moins qualitative que TA (score 3)
- 4.7 — Limites et compromis
  - Limite 1 : Perte d'informations complémentaires
    - Si source A a telephone et source B a site, mais même score → on perd une des deux infos.
    - Mitigation : L'étape 2 récupère ces infos via agrégation par codens.
  - Limite 2 : Biais en faveur de certaines sources
  - Limite 3 : Ne détecte pas les doublons avec clés différentes
    - Si deux fiches ont cle_complete différentes (ex: faute de frappe dans le nom), elles ne sont pas dédoublonnées.
    - Mitigation : C'est le rôle des 10 clés (étape 3) et de la création des codens (étape ultérieure).

Presented with xmind