OGR_RESTO : 5. Rapprochement avec N-1 "pas gardées" et "fermées"

Cette étape identifie les fiches de l'extraction N qui correspondent à des établissements déjà écartés ou fermés lors de la campagne précédente (N-1).

Objectif : éviter de les revalider inutilement.

5.1 — Contexte et objectif

- Situation :
  - La campagne N-1 a déjà validé des milliers de fiches
  - Certaines ont été marquées "pas gardées" : doublons, adresses erronées, non-restaurants…
  - D'autres ont été marquées "fermées" : établissements disparus, radiés…
- Problème :
  - Ces fiches peuvent réapparaître dans les nouvelles extractions N
  - PJ/TA n'ont pas mis à jour leurs bases
  - SIRENE contient toujours l'établissement fermé
- Solution : Rapprocher les extractions N avec les fiches rejetées N-1 pour :
  - ✅ Gagner du temps : pas de revalidation manuelle
  - ✅ Cohérence temporelle : un resto fermé en 2022 a peu de chances d'être rouvert en 2025
  - ⚠️ Alerte : si une fiche "fermée N-1" réapparaît dans PJ/TA → peut-être une réouverture à vérifier

5.2 — Rapprochement avec "pas gardées"

Étape 5.2.1 — Création des clés N-1

Recalcule les 10 clés de rapprochement :

Pourquoi recalculer les clés ?
- Les données N-1 peuvent avoir un format légèrement différent (version SAS antérieure)
- Les règles de nettoyage ont pu évoluer
- Garantit la compatibilité entre N et N-1

Résultat : Table temporaire PAS_GARDES_N1 avec ~500 à 2000 fiches rejetées en N-1, avec leurs 10 clés de rapprochement.

Étape 5.2.2 — Rapprochement en cascade (6 passes)

Étape 5.2.3 — Les 6 passes successives

Chaque passe utilise une clé différente, de la plus stricte à la plus large :

1	cle_complete	⭐⭐⭐⭐⭐ Fiche exactement identique
2	cle_complete2	⭐⭐⭐⭐ Nom de voie légèrement différent
3	cle_pcompl	⭐⭐⭐⭐ Complément d'adresse manquant
4	cle_comp_ss_num	⭐⭐⭐ Numéro de voie manquant
5	cle_pcompl2	⭐⭐⭐ Variante nom voie + sans compl
6	cle_pcompl2_ss_num	⭐⭐ La plus large (sans n° ni compl)

Étape 5.2.4 — Exemple concret

Fiche rejetée en 2022 :
- denomination_f = "SNACKDUCOINDRUE"
- numvoie = "8"
- typevoie = "RUE"
- nomvoie = "VICTOIRE"
- codpost = "75009"
- villenorm = "PARIS"
- → cle_complete = "SNACKDUCOINDRUE8RUEVICTOIRE75009PARIS"
- → cle_pcompl2_ss_num = "SNACKDUCOINDRUEVICTOIRE75009PARIS"

Motif rejet → : "Pas un restaurant, c'est un kebab ambulant"

Fiche PJ 2025 :
- denomination_f = "SNACKDUCOINDRUE"
- numvoie = "" ← PAS DE NUMÉRO
- typevoie = "RUE"
- nomvoie = "VICTOIRE"
- codpost = "75009"
- villenorm = "PARIS"
- → cle_complete = "SNACKDUCOINDRUERUEVICTOIRE75009PARIS"
- → cle_pcompl2_ss_num = "SNACKDUCOINDRUEVICTOIRE75009PARIS" ← MATCH !

Rapprochement

1	cle_complete	❌ Non (numéro différent)	pas_garde_n1 reste vide
2	cle_complete2	❌ Non	pas_garde_n1 reste vide
3	cle_pcompl	❌ Non	pas_garde_n1 reste vide
4	cle_comp_ss_num	❌ Non	pas_garde_n1 reste vide
5	cle_pcompl2	❌ Non	pas_garde_n1 reste vide
6	cle_pcompl2_ss_num	✅ OUI	pas_garde_n1 = 1

pas_garde_n1 = 1 : FLAG → cette fiche N correspond à une fiche rejetée N-1

5.3 — Rapprochement avec "fermées"

Même logique que "pas gardées", mais avec un flag différent : ferme_n1 = 1

Différence clé : interprétation du flag
- pas_garde_n1 = 1 — Fiche invalide (doublon, erreur…) — ❌ REJETÉE automatiquement
- ferme_n1 = 1 — Établissement fermé en N-1 — ⚠️ ALERTE : à vérifier si réouverture

Pourquoi différencier ?
- Imaginons une fiche flaggée ferme_n1=1 qui réapparaît dans TripAdvisor N :
  - TripAdvisor = données récentes (scraping régulier)
  - Présence sur TA = probable réouverture ou erreur N-1

  Résumé : Présence sur TA = probable réouverture ou erreur N-1
- Alors qu'une fiche pas_garde_n1=1 réapparaissant dans TA : Probable pollution de la base TA → → Rejet automatique sans vérification

Presented with xmind