New Pipeline de BD RESTO

- **Rassemblement des resources**
  - donne a traiter
    - Page jaune
    - TripadVisor
  - Source STOCK (SIRENE actifs)
  - Source FERM (SIRENE fermés)
- **Suppression des doublons dans les données scrap**
  - Suppresion des doublons dans Page jaune
  - Suppression des doublons dans TripadVisor
- **Normalise les adresses: découpage automatique, validation automatique, geocodage automatique**
  - API
    - Géoplateforme IGN (ex-BAN) API BAN (Base Adresse Nationale)
      - Géocode et valide les adresses françaises. Retourne un score de fiabilité (0 à 1), les coordonnées GPS, et l'adresse normalisée. Tolérante aux fautes de frappe.
  - NB
    - Différence entre une Commune et une Ville
      - Commune
        - La plus petit division administrative de territoire française
      - Ville
        - n'a pas un status adinistratif précis
        - On parle de ville quand une commune est important, dense et ubranisée
    - Code insee
      - code commune INSEE : l'identifiant officiel et unique d'une commune en France
      - code à 5 chiffres
        - Gére par l' INSEE (Institut National de la Statistique et des Etude Economiques)
      - Structure du code
        - 1- 2 : Numéro du département
        - 3 - 5 Numéro séquentiel de la commmune dans le département
      - Le code INSEE ne change pas quand le nom de la commune change (commune nouvelles)
  - OBJECTIF
    - Avoir une adresse decoupe, et geocode, code postal, code insee
- **Fussionne les données a traité : Page Jeune et TripadVisor**
  - Fussionne les donnes nouveaux : Page jaune et Tripavisor
  - Comparaison entre le nom, et adresses
    - utilisation des differents algorithme
      - levenshtein
        - Distance d'édition
          - "Chartier" vs "Chartiet" (1faute)
      - Jaro-Winker
        - Bonus pour préfixe commun
          - "Bouillon" vs "Bouill"
      - Token Set Ratio
        - Ordre des mots indifférent
          - "Le Bouillon Chartier" vs "Chartier le Bouillon"
      - Sequence Matcher
        - Longest Common Subsequence
          - Match général
    - Distance Geographique
      - Cacluer a partir de la formule de Haversine qui tien compte de la courbure de la terre
        - avec une seuil
          - 0 - 50m
            - Meme adresse quasi certaine -> scorre distance = 100
          - 50 - 150m
            - Même rue possible déménagement -> score distance = 70
          - 150 - 500m
            - Même quartier, doute -> score distance = 30
          - > 500m
            - Restaurants différents -> score distance = 0
    - Numéro telephone
  - OBJECTIF
    - Parfois on trouve le meme restaurant dans les differents sources
      - On les regrouper
- **Recherche dans le SIRENE**
  - OBJECTIF :
    - Prendre des informations importants comme le CODE NAF
      - CODE NAF : Nomenclature d'activité
    - CODE NAF pertinents pour les restaurants
      - 56.10A / 56.10B / 56.10C / 56.30Z
- **Filtres les données déjà ecartés ou fermés lors de la compagne précédente**
  - On prend tous les données déjà fusionnée, faire une recherche dans les données déjà écarté ou ferme lors de la compagne précédente.
  - Ici j'ai besoin plus d'idee mais l'objectif est de apartir des donnée precedent (l'année dernière, il y a des donne pas garde pour une raison et il y a des restauranst renseigner ferme, et je veux filtre les restaurant pas garde, et apres les restaurants ferme.
    - apres
      - pour les donnes qui sont pas garder, on les jettes
      - pour les données ferme on fait une recherche s'il son reouvert...
  - On classe par categorie
    - Cat. A
      - Rejeté définitif
        - Adress n'existe pas (Scroe BAN < 0.3)
        - le SIRET corresponse à une activté non-restaurant (boulangerie, pressing)
    - Cat. B
      - Fermé confirmé
        - Siren état F ou Google "premanently closed" Gardés en base avec une date_fermeture.
          - Ré-verfication automatique aprés 12 mois
            - si toujours fermé passe en Cat. A
    - Cat. C
      - Ecarté par doute
        - Adresse valide mais pas assez de signaux pour confirmer
          - absent d'OSM, pas de site web, pas d'avis récents
- **Filtres les données a partir des donnée validée**
  - On cherche dans les restaurants qui sont déja validé avant chaque nouvel restaurant
    - Resultat
      - Tous les restaurants trouver sont présenter comme déja valider.
  - On cherche dans les donnes restaurant tous les restaurants déja valide l'année dernière.
    - Resultat
      - Tous les restaurants validée precedent non trouve sont susceptible de ferme ou déplacer.
        - On garde pour une recherche plus profond.
- **Séparation des données déja validé sans aucune doute avec les données douteux**
  - Liste des données validé automatique
  - Liste des données valide plus profond
- **Verification automatique des données douteux par des différents API et recherche sur le web.**
  - API
    - Overpass API (OpenStreetMap)
      - Recherche les restaurants référencés dans OpenStreetMap autour de coordonnées GPS. La présence dans OSM est un signal fort d'activité. Fournit aussi téléphone, site web et horaires quand disponibles.
    - API Sirene (INSEE)
      - Donne l'état administratif officiel d'un établissement français : A (actif) ou F (fermé). Basé sur le répertoire SIRENE qui recense 36 millions d'établissements depuis 1973.
  - Vérification HTTP (site web)
    - Vérifie si le site web du restaurant répond encore (HTTP HEAD). Un domaine mort ou une erreur 404 est un signal fort de fermeture définitive.

Presented with xmind